
AI 자율제어기(GEAS Ver3.0) 연구개발결과서(기술 문서)

2025. 12. 23

목 차

I. 연구개발개요	3
1. 연구개발 목적	3
2. 연구개발 필요성	3
3. 연구개발 범위	5
II. 국내외 기술 개발 현황	6
1. 스마트온실 환경제어 기술 현황	6
2. AI 기반 환경제어 연구·산업 동향	6
3. 물리 모델링, 디지털트윈, 파라미터 추정 연구 동향	7
4. 본 연구의 차별성 및 기술적 공백 대응성	7
III. 연구수행 및 결과	10
1. 데이터구조 및 입력 로그 구성	10
2. 파생변수 및 물리 파라미터 정의와 활용 구조	14
3. 센서 데이터 보정 및 신뢰성 확보 구조	17
4. 물리 파라미터 식별 방법	21
5. AI 자율제어 정책 설계 및 보정 구조	32
6. AI 자율제어 견고성 검증 방법론	44
IV. 연구 결과 종합 및 기술적 한계와 확장 방향	60
1. 연구 결과의 종합적 요약 및 구조적 성과 정리	60
2. 적용 범위 정의 및 기술적 전제 조건	61
3. 현재 AI자율제어·검증 엔진의 구조적 한계점	63
4. 한계에 대한 설계적 완화 전략 및 단계적 고도화 전략	65
5. 현장 적용성 및 실증 확장 가능성	66
6. 향후 연구 및 기술 고도화 방향	67

1.1. 연구개발 목적

□ AI 자율제어 기술 개발 목표

- 스마트팜 AI 자율 환경 제어 기술은 작물의 생육 환경을 실시간으로 최적화함으로써 생산성과 에너지 효율을 동시에 높이는 핵심 기술
- 그러나 기존 제어기술(ML 기반 제어·AI 강화학습 기반 제어 등)은 시설별 물리 환경의 차이(단열, 체적, 환기율), 장비 구성의 비표준성, 물리·생리 제약 미반영 등 구조적 한계로 인해 예측·제어 성능의 일관성과 현장 적용성이 크게 제한됨
- 본 연구는 이러한 기술적 한계를 해결하고, 전국·다시설·이종환경에서도 자동 적용 가능한 AI 자율제어 알고리즘을 개발하기 위해 다음 기술목표를 달성하고자 함

□ 본 연구의 궁극적 목표

- 센서값 기반 입력이 아닌 물리·생리 상태공간 기반 제어(Physics-aware Control) 구현
- 온실별 물리 파라미터 자동 식별을 통한 이종환경 적응형 제어
- 장비 재원의 부재·편차를 데이터 기반으로 추정할수 있는 모듈 탑재
- 생리·광·열·결로 제약을 내재화한 안전 제어정책 생성 및 실시간 정책 갱신 (Policy Adaptation)
- 다지역 실증을 통해 실제 현장에서 재현 가능하고 설명가능한 AI 제어기 구현
- 즉, 본 연구의 목적은 환경·장비 이종성에도 불구하고 물리 일관성을 유지하며 작동하는 범용 AI 자율제어 엔진을 개발하는데 있음

1.2. 연구개발 필요성

□ 스마트 온실 물리적 환경의 이종성

- 국내 스마트팜은 지역·시설별로 온실 구조, 단열 성능, 환기율, 열용량 등 물리적 특성이 상이함
- 동일 제어 알고리즘을 적용하더라도 실제 내부 온도·습도 응답이 다르며, 제어 효율과 에너지 소비 편차가 커 예측·제어 일관성이 떨어짐
- 또한, 대부분의 농가에서는 온실의 설계 제원(단열계수, 체적, 열용량 등)을 보유하지 않거나 불확실하여, 특정 지역이나 시설에서 학습된 AI 제어 알고리즘을 그대로 적용할 경우 제어 성능이 현저히 저하되는 문제가 발생함
- 따라서, 실측 데이터만으로 물리 파라미터를 자동 식별하고 제어정책에 반영하는

물리 적응형(Physics-adaptive) 제어기술이 반드시 필요함

□ 제어 장치(Actuator) 구성의 비표준성 및 제원 부재

- 환기창, 순환팬, 난방기, 차광커튼 등 제어기기의 종류·출력단위·응답특성이 농가마다 다르고, 심지어 정확한 제원 문서조차 없는 경우가 대부분임
- 이로 인해 동일 명령이라도 시설별 제어 결과가 크게 차이ナ며, 이는 AI 제어정책의 재현성을 심각하게 저해함
- 따라서, 제원이 없는 장비가 설치된 온실이라도 데이터 기반으로 장비 응답식을 자동 학습·추정할수 있는 기술이 필수적임. 이는 기존 제어기·연구모델에서는 전혀 다루지 않았던 핵심 기술 공백 영역임

□ 물리·생리 제약의 미반영 문제

- 기존 AI 제어기는 센서값만을 입력으로 사용하여 실제 재배환경의 물리적 상태(VPD, 이슬점여유, 누적광, 열손실률, 환기손실 등)를 고려하지 못함
- 이로 인해 발생하는 야간 별로(병해 발생), 과습·저 VPD(기공 저항 증가·동화 저하), 급격한 환기 개도(내부 온도 급강하·스트레스), 차광 적용 오류(광부족 혹은 과열) 등의 문제가 빈번히 발생함
- 따라서 결로·과습·열손실·램프율 등을 포함한 물리 적응형 제약 기반 정책 생성 기술이 반드시 필요함

□ 페루프 제어의 안정성과 재현성 확보 필요

- 기존 ML·AI 제어 기반 환경에서는 온·습도 등 센서값을 그대로 입력으로 사용하므로, 실제 온실의 물리 반응(열손실, 환기효과, 누적광, 결로 위험 등)을 반영하지 못한 채 제어 결정을 수행하게 됨. 이로 인해 환경 노이즈나 장비 편차가 있을 경우 동일 조건에서도 서로 다른 제어 결과가 나타나며, 제어 품질의 재현성을 확보할 수 없음
- 특히 스마트온실은 시설 구조와 장비 제원이 모두 상이하기 때문에 동일한 제어 명령이라도 시설별 환기량·광투과율·열교환량이 크게 달라짐. 이 경우 상태-행동-응답 간의 물리적 일관성이 무너져 예측 모델이 제어정책에서 가정한 반응과 실제 온실 반응이 불일치하게 됨
- 이러한 문제를 해결하기 위해서 상태-행동-전이가 물리적으로 연결되는 구조적 페루프(Closed-loop) 제어체계가 필수적
 - 상태(State)는 센서값이 아니라 VPD, DLI, SunRatio, 열손실률 등 물리·생리 기반 파생상태량으로 재구성되어야함
 - 행동(Action)은 장비 개도율을 그대로 사용하지 않고 장비 반응식을 통해 물리 효과(풍량, 투과율, 열유입률 등)로 변환되어야함
 - 전이(Transition)는 온실의 실제 응답을 관측하여 물리 파라미터(UA, C, ACH,

n)와 정책을 지속적으로 보정하는 구조

- 본 연구는 폐루프 제어 구조를 통해 단순히 모델을 개선하는 수준이 아닌, 온실의 물리·장비 이중성에도 불구하고 제어정책의 안정성과 재현성을 확보하기 위한 필수 기술 기반이며, 이는 기존 스마트팜 제어 기술이 해결하지 못한 구조적 문제를 대응하는 핵심 연구 필요성에 해당함

1.3. 연구개발 범위

- 본 연구의 범위는 스마트온실의 물리적·기기적 이중성에 대응하기 위한 데이터 기반 물리 파라미터 식별, 제어정책의 적응형 보정 구조 개발, 안정성 중심 물리·생리 제약 반영 및 보수적 제어 설계로 구성됨

연구내용	세부 범위
스마트온실 물리 이중성 대응 구조 개발	- 실측 데이터(온도, 외기, 제어 로그 등) 기반 온실별 물리 파라미터 자동 식별 - 장비 제원 미확보 환경을 고려한 데이터 기반 역추정 (Reverse Identification) 기법 개발 - Drift 대응을 위한 물리 파라미터 자동 보정 루프 설계
AI 자율제어 알고리즘 개발	- 환경·제어·로그 기반 상태-행동-결과 모델링 - VPD·ΔT_{cond}·DLI 등 물리·생리 기반 상태벡터 생성 엔진 구축 - 장비 반응식·장비 추상화 설계 - 실측 기반 정책 보정(Policy Adaptation) 및 오차 학습 (Error-Learning) 구조 개발 - 단기 예측-정책-제어가 연결된 폐루프 자율제어 아키텍처 구현
안정성 중심 물리·생리 제약 반영 및 보수적 제어 설계	- 결로·과습·과열·환기 부족 등 물리적 안전제약 정의 및 수식화 - 파생변수 기반 제약조건을 정책 탐색·정책 실행에 직접 반영하는 Constrained Policy Search - 실측·시뮬레이션 기반 정책 안정성 검증(Backtesting & Robustness test)

2.1 스마트온실 환경제어 기술 현황

□ 국내 복합환경제어 중심의 현장 기술 현황

- 국내 스마트온실 현장에는 온·습도·이산화탄소·일사 등 센서 계측과 환기창·난방·팬·커튼 등 구동기를 통합 제어하는 복합환경제어 시스템이 폭넓게 보급되어 있음. 예를 들어 코리아디지털의 팜스큐브는 센서/구동기 통합, LoRa·LTE 기반 연결, 원격 제어 및 경보 기능 등 운영 자동화 기능을 제공하는 개방형 복합환경제어 플랫폼으로써 제품을 소개함. 다만 이 기술은 일반적인 설정값·밴드·시퀀스(순차제어/동시제한) 등 규칙 기반 운용이 중심이어서, 시설별 물리 차이와 장비 편차가 존재할 때 같은 명령이 같은 환경 제어 결과로 이어질 수 있는 재현성이 떨어질수 있으며, 장기 최적화보다는 안전 운전·편의성에 초점이 맞추어져 있음

□ 해외 기후컴퓨터 중심의 산업 표준 현황

- 해외 상업온실에서는 Priva, Hoogendoorn 등 기후·관수·에너지 프로세스를 통합 관리하는 기후컴퓨터가 사실상 표준 인프라로 자리 잡았고, 측정-설정-실행의 안정적 자동운전을 제공함
- Priva는 Connex를 통해 기후·조명·관수·에너지의 통합 제어를 제공한다고 설명하며 Hoogendoorn은 iSii 계열 프로세스 컴퓨터가 온실 운영 전반(기후, 관수, 에너지)을 자동 제어한다고 주장함

2.2 AI 기반 환경제어 연구·산업 동향

1) 국내 동향: 운영·의사결정 지원 중심의 플랫폼화

- ioCrops는 AI·로보틱스·센서·데이터 플랫폼을 결합해 무인 자동화 온실을 지향함
- 이러한 접근은 다수 농장 원격 관리와 운영 표준화에 강점이 있으나, 전국·다시설·이종환경에서 자동 적용 가능한 페루프 자율제어 관점에서는 시설들의 물리적 차이와 장비 비표준성, 그리고 물리·생리 제약을 상태, 전이, 행동 구조에 내재화하는 방식의 고도화가 필요함

2) 해외 동향: 자율제어와 운영자 경계의 상용화

- Koidra는 Kopilot(실시간 기후·관개 제어)와 DataPilot(데이터 통합·알람) 형태로 상용 온실에서 AI 기반 자동화를 제공한다고 설명하며, AGC(Autonomous Greenhouse Challenge)에서 순이익 27.8% 최적화 성과를 사례로 제시함

- Blue Radix는 Crop Controller를 기후·관개 자율 제어 솔루션으로 소개하며, 기존 기후컴퓨터와의 연동을 통해 실시간 의사결정을 자동화하는 구조를 강조함
- 그러나 상용 제어제어 솔루션들은 일반적으로 운영자 전략/경계를 전제로 하거나, 특정 작물·시설·운영 철학에 맞춘 초기 튜닝과 반복 개선이 필요하다는 점에서 완전 무설정·범용 자동 적용과는 여전히 간극이 존재함

2.3 물리 모델링, 디지털트윈, 파라미터 추정 연구 동향

□ 물리 기반 온실 모델의 전통적 축과 한계

- 온실 환경 모델링은 열·수분·이산화탄소·에너지 전달을 기반으로 한 물리 모델이 오랜 기간 연구되어 왔으며, 이는 해석 가능성과 제약 반영에 강점이 있으나 파라미터 튜닝 부담과 시설별 이종성으로 인해 현장 배포가 어렵다는 문제가 반복적으로 지적됨

□ 미분 가능(Differentiable) 물리 시뮬레이션 및 최적제어 결합 추세

- Nguyen(2022)은 온실 기후 및 작물 동역학을 선형 미분방정식 시스템으로 구성하고 이를 해석적으로 풀어 장기간 시뮬레이션이 가능한 완전 미분가능 물리 기반 온실 시뮬레이터를 제안했으며, 실제 데이터로 파라미터를 학습(자동 추정)하는 방향을 제시함
- 이러한 계열의 연구는 MPC와 같은 최적제어 기법과 결합 가능하다는 점에서 디지털트윈 기반 제어 고도화 흐름을 강화함

□ 데이터 기반 최적화·기후 목표값 최적화 연구의 병행

- 최근에는 온실 기후 목표값 자체를 에너지·수량 관점에서 최적화하는 연구들도 제시되고 있으며, 시뮬레이션 기반으로 제어 과정을 평가하는 접근이 병행되고 있음

2.4 본 연구의 차별성 및 기술적 공백 대응성

□ 스마트온실 물리적 환경 이종성 대응 차별성

- 기존 스마트팜 AI 환경제어 기술은 특정 시설 또는 제한된 환경에서 학습된 모델을 다른 온실에 그대로 적용하는 구조로 인해, 온실별 단열 성능, 체적, 환기율, 열용량 차이를 충분하지 못하는 한계를 가짐
- 이로 인해 동일한 제어 알고리즘을 적용하더라도 시설별 내부 온·습도 응답이 상이하게 나타나며, 제어 효율과 에너지 소비 측면에서 일관된 성능을 확보하기 어려움
- 본 연구는 이러한 문제를 해결하기 위해, 설계 제원이 불확실하거나 존재하지 않는 온실 환경에서도 실측 데이터만을 이용해 열손실계수, 열용량, 환기율 등 핵

심 물리 파라미터를 식별하는 구조를 제안함

- 이를 통해 특정 시설에 종속되지 않고, 이종 환경 간에도 물리적으로 일관적 제어 정책을 적용할 수 있는 물리 적용형(Physics-adaptive) AI 자율제어 구조를 구현한다는 점에서 기존 기술과의 차별성을 가짐

□ 제어 장치 구성 비표준성 및 제원 부재 대응

- 국내 스마트온실 현장에서는 제어 장치 종류, 출력 단위, 응답 특성이 농가별로 상이한 경우와 장비 제원 문서가 부재한 경우가 대부분. 이러한 환경에서는 동일 제어 명령이라도 실제 물리적 효과가 시설마다 달라져, AI 제어정책의 재현성과 확장성이 크게 저하됨
- 기존 제어기 및 연구 모델은 이러한 장비 비표준성을 전제로 한 자동 적응 구조를 다루지 못했으며, 장비 제원이 주어졌다는 가정을 암묵적으로 포함하는 경우가 많음
- 본 연구는 장비 제원 정보가 없는 상황을 전제로, 제어 로그와 환경 응답 데이터를 이용해 장비 반응식을 역으로 추정하는 데이터 기반 장비 응답 역추정 구조를 도입하였음. 이를 통해 장비 구성과 제원이 상이한 환경에서도 행동을 단순 개도율이 아닌 물리적 효과 수준으로 해석·변환함으로써, 장비 이종성에 대한 구조적 대응이 가능하다는 점에서 기술적 공배를 보안함

□ 물리·생리 제약 미반영 문제에 대한 대응

- 기존 AI 환경제어 시스템은 주로 온도, 습도, 이산화탄소 농도 등 개별 센서값을 상태(State)로 사용하여 제어 결정을 수행하며, 실제 재배 안정성과 직결되는 물리·생리 상태를 명시적으로 고려하지 못함. 이로 인해 야간 결로로 인한 병해 발생, 과습 또는 저 VPD로 인한 동화 저하, 급격한 환기로 인한 온도 스트레스, 차광 오작동에 따른 광 부족 또는 과열 등의 문제가 현장에서 반복적으로 발생함
- 본 연구는 센서값 자체가 아닌 VPD, 이슬점 여유, 누적광, 청천 대비 일사 비율, 열손률, 등 물리·생리적 의미가 내재된 파생 상태량을 상태공간의 기본 요소로 정의하고 결로·과습·과열·환기 부족·급격한 램프 변화와 같은 물리적 위험요인을 제약 조건으로 수식화하여, 제어 정책 탐색과 실행 단계에 직접 반영하는 제약 기반 제어 구조를 채택함. 이는 제어 성능 뿐만 아니라 재배 안정성 운영 안정성을 동시에 고려하는 설계로, 기존 센서값 중심 AI 제어와의 명확한 차별성을 가짐

□ 페루프 제어의 안정성과 재현성 확보 측면의 차별성

- 기존 ML·AI 기반 환경제어 방식은 센서값을 그대로 입력값으로 사용하는 구조

가 많아, 실제 온실의 물리 반응과 제어정책이 가정하는 반응 간의 불일치가 누적되는 문제가 존재함


- 특히 시설 구조와 장비 제원이 상이한 스마트온실 환경에서는 동일한 제어 명령이라도 환기량, 광 투과율, 열교환량이 크게 달라져 상태-행동-응답 간 물리적 일관성이 쉽게 붕괴될 수 있음
- 본 연구는 이러한 문제를 해결하기 위해 상태-행동-전이가 물리적으로 연결되는 구조적 폐루프 제어 체계를 핵심 설계 원리로 채택함. 상태는 센서값이 아닌 물리·생리 기반 파생상태로 재구성되고, 행동은 장비 반응식을 통해 물리 효과로 변환되며, 전이는 온실 응답을 이용해 물리 파라미터와 정책을 지속적으로 보정하는 구조로 설계됨

Ⅲ 연구 수행 내용 및 결과

3.1. 데이터 구조 및 입력 로그 구성

□ 시스템 개요 및 설계 목표

- 본 시스템은 스마트온실에서 수집되는 환경·제어 로그를 실시간으로 수집·정규화하고 일출·일몰·청천 일사량 산출 및 시간 적분 기반 누적 일사 계산을 수행한 후, 생리·광·열 환경 정보를 제공할 수 있는 파생변수를 자동 생성하는 기능으로 구성됨. 이 과정은 기존의 “단순 센서값 입력 기반 제어체계”에서 벗어나, 물리적 의미가 내제된 환경 상태량을 정규화하여 AI 제어기가 직접 활용 가능한 통합 상태벡터(State vector)를 제공하는데 목적이 있음
- 전체 파이프라인은 크게 데이터 수집 계층, 시간 정규화 계층, 청천 일사 모델 및 누적 일사량 산출 계층, 파생변수 계산 계층의 5단 구조로 구성되며, 각 계층의 출력이 다음 계층의 입력으로 연속적으로 전달되도록 설계되어 있음



□ 데이터 처리 파이프라인의 계층 구조 정의

계층	주요역할	세부기능	입력 데이터	출력 데이터	다음 계층으로 전달되는 내용
1. 데이터 수집 계층	- MySQL에서 센서, 제어 데이터 수집 - 실시간 스트림 제공 - 제어 명령 이력	- 신규 row polling(실시간) - 제어 API 호출 로그 기록	- MySQL DB 로그(외기, 내기)	- 정렬된 RAW 로그	- 시간 정규화 계층에서 Timestamp 변환 및 금일 데이터 분리

	기록				
2. 시간, 데이터 정규화 계층	- 시계열 구조 정렬 - 금일 기준 시간창 생성 - 단위·스키마 통일 - 결측치 보정	- 금일 00시-24시 window 계산 - 결측값 보정 - 컬럼명 표준화 - 제어 장치 수치 표준화 - 제어기 입력 형태로 정렬	- RAW 로그 DATAFRAME	- 표준화된 시계열 - 제어 입력 형식의 회신 row	- 청천모델 계층에서 일사·일출/일몰 계산에 필요한 표준화된 시계열 제공
3. 청천 일사 모델 & 누적 일사량 처리 계층	- 금일 기준 청천 GHI 곡선 생성 - 실측 일사량 적분 - 목표 누적광 ETA 계산	- 위도·경도 기반 일출/일몰 계산 - GHI 적분으로 누적 J/cm2 계산 - 실측 광량을 동일한 방식으로 적분 정렬 - 목표 J/cm2 도달 시간 계산	- 표준화된 시계열 - 데이터프레임(정규화 Step 출력)	- 청천 누적광 - 실측 누적광 - LightETA(예상 도달 시간) - 일출, 일몰 시간	- 파생변수 엔진에서 DLI·SunRatio·LightETA 계산에 직접 사용
4. 파생변수 계산 계층	- 생리·광·열 상태를 정량화하는 파생변수 계산 - AI 제어·모델 입력으로 사용하는 상태 벡터 생성	- 습도/결로 모듈(VPD, Tdew, dTcond 계산, 1시간 누적 과습시간, 10분 후 결로 위험 단계 예측) - 광/일사 모듈(DLI 적분, 청천 대비 누적광, LightETA 전달)	- 정규화된 시계열 - 청천누적광 - LightETA - 일출·일몰 시간	- 통합 상태벡터	- 최종 출력 계층(제어기·예측 모델·관제·알림)
5. 최종 출력 계층	- 상위 제어기·모델·관제 시스템이 즉시 사용할 수 있는 정보 제공	- 딕셔너리 형식의 상태 벡터 - 생리·광·열·결로 안정성을 모두 포함한 해석 가능한 상태값 제공	- 통합 상태벡터	- 시스템 외부에서 직접 사용	

1) 데이터 수집 계층

- 데이터 수집 계층은 MySQL로부터 센서·제어 로그를 호출 명령이 들어올 때마다 실시간으로 불러오는 방식으로 확보하며, 모든 원시 로그에 대해 시간 기준 정렬을 수행한 뒤 정렬된 RAW 로그 형태로 상위 계층에 전달하는 역할을 수행함
- 본 계층은 센서 주기·간헐적 전송 지연 등으로 인해 로그의 시간 순서가 뒤섞일 가능성을 제거하고, 결측·미기록 구간이 존재할 수 있는 스마트팜 환경의 특성상 AI 처리의 출발점이 되는 데이터 신뢰성 확보를 담당함

2) 시간·데이터 정규화 계층

- 시간·데이터 정규화 단계에서는 금일(00-24시) 기준 데이터 창을 생성하고, 각 센서 단위·스키마를 통일하며, 결측치·왜곡치에 대한 보정을 수행함

- 또한 제어기 입력 형태를 표준화 하여 상위 모듈에서 그대로 사용할 수 있도록 데이터 품질을 확보함

3) 청천 일사 모델 계층

- 본 계층은 정규화된 시계열을 입력으로 받아, ①위·경도 기반 일출·일몰 산출, ② 청천 GHI 곡선 생성, ③실측 광량의 시간 적분, ④목표 누적광의 도달 시각(ETA) 계산을 수행함
- 이 과정은 실제 환경 광조건을 이해하고, 광 관련 파생변수 계산의 기반이 됨. 특히 LightETA는 당일 광 확보량을 예측하는 핵심 지표로, 작물의 광포화·과열·차광 정책의 근거가 되므로, 파생변수 모듈에서 직접 사용하는 방식으로 설계함

4) 파생 변수 계산 계층

- 파생변수 계산 계층은 정규화된 시계열 + 청천 일사 정보 + LightETA를 기반으로 생리·광·열·결로와 관련된 상태량을 생성함
- 파생 변수 계산 모듈이 전체 연산을 수행하며 세부적으로는 ①생리·습도 관련 상태(VPD, Tdew, dTcond, 1시간 누적 과습시간, 저VPD 누적 시간, 10분 후 결로 위험), ② 광환경 관련(DLI, SumRatio, LightETA), ③열환경 관련(dT, ACH_min_day/night)을 계산함
- 이 모든 상태량은 개별 센서값이 아니라 물리·생리적 의미가 내제된 상태벡터를 구성하며, 제어기 적용과 직접 연결됨

5) 최종 출력 계층

- 최종 출력 계층은 상위 제어기·예측 모델·관제 시스템이 즉시 사용할 수 있는 딕셔너리 형식의 통합 상태벡터를 제공하며 생리·광·열·결로 안정성을 모두 포함한 해석 가능한 상태값을 전달함
- 이를 통해 외부 시스템은 추가 변환 없이 바로 상태벡터를 입력으로 사용하여 AI 자율제어, 단기 예측, 관제 대시보드 표시, 경보 발령 등에 활용할 수 있음

□ 계층 간 연계를 통한 페루프 자동화 구조

- 본 파이프라인은 각 계층의 출력이 다음 계층의 입력으로 유기적으로 연결되도록 설계되어 있으며, 이는 단순한 선형 데이터 처리 절차가 아니라 센서 로그가 단계적으로 물리적 의미를 획득해 가는 누적적 정보 변환 체계를 이룸. 이러한 구조적 연계성은 기존의 AI 환경제어 알고리즘(v2.5)이 활용하던 단순 센서값 기반 입력 방식과 달리, 물리·생리적 맥락이 반영된 상태정보를 토대로 제어 정책을 생성할 수 있도록 한다는 점에서 근본적인 차별성을 가짐
- 데이터 수집 단계에서 확보된 RAW 로그는 시간·단위·스키마가 표준화가 되어

있지 않으므로, 이를 정규화 계층에서 통일된 시간축·데이터 구조로 변환함으로써 이중 시설·이중 장비에서도 일관된 품질의 시계열 데이터 확보가 가능함. 이는 AI 모델이나 제어가 잘못된 센서 순서, 누락, 단위 불일치로 인해 오판하는 문제를 원천적으로 차단하는 역할을 함

- 정규화된 시계열은 이어서 청천 일사 모델 계층에서 위·경도 기반 태양 위치, 청천 GHI, 누적 일사 에너지, 목표광 ETA 등 물리적으로 해석된 광환경 정보로 재구성됨. 이 단계는 난방·차광·환기 제어에서 필수적인 광-열-에너지 트레이드 오프를 설명할 수 있게 하며, 기존 제어 방식에서는 제공할 수 없었던 물리 기반 입력을 생성함
- 물리적 맥락을 획득한 데이터는 파생변수 계산 계층에서 생리·광·열·결로 상태량으로 통합되고 직적접적으로 제어 정책과 제약에 연결되는 상태 공간으로 변환함. 이는 제어기 입력의 품질을 근본적으로 끌어올리는 설계적 장치이며, 센서 노이즈나 시설 편차에도 강건한 정책 생성을 가능하게 함
- 마지막으로, 상태량은 하나의 통합 상태벡터로 결합되어 자율제어기·단기 예측 모델·관제 시스템이 즉시 활용할 수 있는 형태로 제공됨

□ 기존 센서값 입력 방식과의 비교 및 차별성

- 스마트온실 환경제어 시스템은 온도, 습도, 이산화탄소, 일사량 등 개별 센서값을 그대로 제어기의 상태로 입력하는 구조를 사용하였음. 이러한 방식은 데이터 처리 구조가 단순하단 장점이 있으나, 센서값 자체가 실제 재배 환경의 물리·생리적 상태를 충분히 설명하지 못한다는 구조적 한계를 지님
- 센서값 입력 방식에서는 시간·단위·스키마 정합 과정이 제어 구조 내부에 포함되지 않은 경우가 많으며 센서 로그는 시설별로 수집 주기, 단위, 컬럼 구성, 결측 여부가 상이하며 충분히 정규화되지 않은 상태로 제어기에 입력되는 사례가 다수 존재. 이로 인해 동일한 제어 알고리즘이라도 센서 배열 순서, 단위 불일치, 결측치 처리 방식에 따라 제어 결과가 달라지며, 이는 제어 품질의 지현성을 저해하는 주요 원인으로 작용함
- 또한 기존 방식은 광 환경을 순간 관측값 중심으로 사용하고, 일출·일몰 시각, 청천 일사 대비 수준, 누적 일사 에너지와 같은 광의 시간적·에너지적 맥락은 상태 공간에 반영되지 않음. 이로 인해 차광·환기·난방 제어가 단기 센서 변동에 과도하게 반응하거나, 당일 목표 광 확보량을 고려하지 못한채 제어되는 한계가 발생함
- 센서값 기반 입력 구조에서는 VPD, 이슬점 여유, 결로 위험, 누적 과습 시간 등 재배 안정성과 직결되는 상태를 직접적으로 판단하기 어려우며 이러한 제약은 대부분 사후 규칙 설정이나 운영자 경험에 의존하여 보완되는 구조적 한계를 가짐
- 이에 반해 본 연구에서 제안하는 데이터 구조는 센서 로그를 그대로 제어기에

입력하지 않고, 단계적 처리 과정을 통해 물리·생리적 의미를 갖는 상태량으로 변환하여 입력하는 구조를 채택함

- 데이터 수집 이후 시간·단위·스키마 정규화를 수행하고, 청천 일사 모델을 통해 광 환경을 물리적으로 재구성한뒤, 생리·광·열·결로 상태를 대표하는 파생변수를 생성함으로써 제어기에 제공되는 상태벡터의 의미적 품질을 근본적으로 향상시킴

3.2. 파생변수 및 물리 파라미터의 정의와 활용 구조

□ 파생변수 산출 목적 및 필요성

- 스마트온실 환경제어 시스템은 온도, 습도, 이산화탄소 농도, 일사량 등 개별 센서값을 기반으로 작동하지만, 이러한 1차 관측값으로는 작물의 생리 반응·환경 응답·열 수분 교환 동역학을 정량적으로 설명하기 어려움
- 예로써, 실제로 작물이 느끼는 수분 스트레스, 증산 강도, 결로 위험 또는 열적 안정성은 복합 물리량(증기압차, 이슬점, 열손실율) 등으로 표현되어야 좀 더 정확한 정보를 확인할 수 있음
- 기존 AI 환경제어 알고리즘은 주로 온도, 습도, 조도 등 단순 센서값을 직접 입력받아 제어 명령을 산출하는 피드백 구조를 따르나 이러한 방식은 센서값에 내재된 물리적 의미(열·수분 교환, 증산, 결로 등)를 해석하지 못한 채 제어 결정을 수행하므로, 환경 관측→물리·생리 해석→제어 판단의 핵심적 변환 단계가 결여 되어 있음
- 그러므로, 기존 AI 환경제어 알고리즘들은 작물의 실제 생리 안정성이나 온실의 물리적 안전 제약을 동시에 만족시키는 최적 제어를 구현하는데 한계점을 가짐

□ 파생변수 산출의 이론적 근거

- 스마트온실 내 환경 변화는 단일 센서 신호로는 설명되지 않는 열·수분·광 에너지 교환의 복합 시스템으로 구성되어 있음
- 온실 내부 온도, 상대습도, 일사량, 이산화탄소 농도 등 개별 측정값은 단순 상태 지표에 불과하며, 작물의 생리적 반응(증산, 기공 개폐, 결로 발생 등)은 이들 변수가 상호작용하여 형성하는 물리적 상태량으로 결정됨

1) 열·수분 평형이론(Thermo-Hydric Equilibrium)

- 온실 내 공기층은 온도, 상대습도, 수증기압, 이슬점 간의 평형관계로 기술되며, 이들로부터 산출되는 증기압차(VPD, Vapor Pressure Deficit)는 작물 증산속도, 기공 개폐, 병해 발생률과 밀접한 상관을 가짐
- VPD가 과도하게 낮을 경우(과습 환경), 기공 저항 증가 및 병해충 발생률이 상승하고, 반대로 높을 경우(건조 환경)에는 증산 과다 및 생리적 스트레스가 유발

됨

- 따라서 AI 자율제어기는 단순한 RH 대신 VPD를 직접 입력받음으로써, 생리학적 으로 유효한 제어 정책을 도출 가능

2) 광·에너지 수지이론(Radiative-Energy Balance Theory)

- 작물의 생장·동화작용은 광합성 유효광량(PAR, Photosynthetically Active Radiation)의 누적에 의해 결정되며 단기 일사량(W/m^2)을 시간 적분하여 산출되는 DLI(Daily Light Integral, $mol/m^2 \cdot day$)은 작물 생산성 및 차광 커튼 제어의 기준지표로 활용됨
- 또한, 외기 일사량과 내부 조도 간의 비율은 커튼 투과율·일사 손실 보정계수로 변환되어 AI 제어 모델이 광환경을 물리적으로 해석하고, 일사 확보와 온도 과열 간의 균형을 동적으로 조절할 수 있도록 함
- 이와 같은 광·에너지 파생변수는 단순히 조도가 낮다/높다 수준의 반응을 넘어서 온실 내 에너지 유입-손실의 정량적 해석을 가능하게 하여, 난방·차광·환기 간의 최적 에너지 조합(정책)을 학습할 수 있도록 함

3) 물리 파라미터 추정 및 시스템 동특성 식별

- 스마트온실은 구조적 제원(단열성, 체적, 환기면적, 피복재)에 따라 동일 제어 명령에 대한 환경 응답이 상이하게 나타나는 폐루프 동적 시스템
- 따라서 단순 센서 기반 제어는 시설 간 편차를 설명하기 어렵고, AI 제어기의 예측 안정성을 확보하기 위해서는 열손실계수(UA), 유효열용량(C), 환기율(ACH), 일사 유효계수(η) 등의 물리 파라미터를 데이터 기반으로 추정할 필요가 있음
- 본 연구에서는 이러한 물리 파라미터를 단일 구획 모델 기반 식별 절차를 통해 추정하며, 이로써 시설별 동특성에 적용하는 AI 제어 정책 구현을 가능하게 함

□ 파생변수 분류 및 산출식

- 스마트온실 내 복잡한 열·수분·광 상호작용을 AI 자율제어가 물리 제약을 내제화한 최적 제어로 수행할 수 있도록 다음과 같이 3가지 큰 파생변수로 구분함
- ① 증기압차(VPD), 이슬점(Tdew), 이슬점여유(ΔT_{cond})와 같이 생리 및 결로 안전 변수, ② 누적광량(DLI), 청천 대비 누적광비(SunRatio), 광목표 ETA와 같은 광·에너지 균형 변수, ③ 내외기 온도차(ΔT), 풍속(Wind), 강우(Rain), 최소 환기율(ACH_min), 램프율 제한(RampLim) 등 물리 안전 및 기구 한계 변수
- 이들 파생변수는 입력값(제어/학습용), 백테스팅용(정책 검증/물리 추정 검증), 모니터링용(실시간 감시/알림)의 세축으로 운용될 수 있으며, 각 변수들은 해당 목적에 맞는 산출식·최적 산출법을 갖고 특정 제어기(Actuator)의 제어 정책과 직접 연결됨

(1) 생리 및 결로 안전 변수

변수명	산출식 및 의미	역할/이유	제어기 적용
VPD(Vapor Pressure Deficit)	- $VPD = e_s(T)(1 - RH/100)$ - 증산을 유발하는 공기와 잎 표면 간의 증기압 차	- 작물의 수분 스트레스와 증산 강도를 직접 반영 - 단순 RH 보다 생리적 의미를 지니며, 과습(낮은 VPD)은 병해 위험, 과건조(높은 VPD)는 증산 과다로 스트레스 발생	환기 창 · 팬 · 관수 제어
Tdew(이슬점)	- Magnus-Tetens 식으로 RH와 T로 계산	- 공기 중 수증기가 응결하기 시작하는 온도 - 내부 온도가 이슬점에 접근 시 결로 발생	히터 · 커튼 · 환기 창 하한 제약 계산, 결로 방지
dTcond(이슬점 여유)	- 내부 온도 - 이슬점	- 현재 결로 안전 여유 - 0.8~2° C 범위로 안전 제약 설정	히터, 환기 개도 제한, 결로 예보
rh90_min_1h, vpdlo_min_1h	- 1시간 누적 과습시간($RH \geq 90\%$), 저VPD($VPD < 0.5$) 시간	- 과습 누적이 결로 · 병해를 유발하므로 경보 판단에 사용	팬 · 환기 하한
cond_risk_10m	- dTcond 예측치 < 0.8° C 일 때 결로 위험 경보	- 단기(10분 후) 결로 리드타임 확보 경보	히터, 커튼 선제 작동

- 작물의 생리적 안정성과 물리적 안전제약을 동시에 충족하는 제어 입력 값 및 검증 변수

(2) 광·에너지 균형 변수

변수명	산출식 및 의미	역할/이유	제어기 적용
DLI(Daily Light Integral)	$DLI = \int_t^T PPFD(t) \Delta t / 10^6$	- 일일 광합성의 유효광량 근사치 - 작물 생산성 · 동화량 평가 지표	커튼 제어
cs_sum_jcm ₂	청천모델(Haurwitz) 누적 일사량	- 외기조건 대비 광환경 상대 상태를 평가	광보정 · 보완광 제어

SumRatio	실측누적 /청천누적	- 일사 확보율(상대광)	일사 부족 시 커튼 개방, 과열시 폐쇄
LightETA	청천 누적곡선 역탐색으로 목표광 도달 시각 예측	- 오늘 목표광 확보까지 남은 시간을 산출	커튼 타이밍 제어
vent_loss_proxy	환기열손실 근사, 일사와 온도차를 통합	- 광·열 균형 최적화	커튼·환기 복잡 정책 결정

- 조도 수준이 아닌 일사 에너지를 통해 생육·에너지 효율 최적화
- 일사 확보-과열-결로 사이의 트레이드오프 정량적 관리 가능

(3) 물리 안전 및 기구 한계 변수

변수명	산출식 및 의미	역할/이유	제어기 적용
dT(내외기 온도차)	내부 온도 - 외부 온도	- 열손실률, 환기손실 압력의 근사	난방·환기 병용 시 손실 감시
ACH_min(최소환기률)	주/야 정책값($0.1/0.05h^{-1}$), 과습 시 상향 조정	- 환기 부족으로 인한 CO ₂ 축적, 결로 방지	팬/환기 하한 제약
RampLim(램프율제한)	$\pm 15\%$ / 10분	- 제어기의 급변 방지, 기계 피로·헌팅 예방	환기량, 커튼 제어 변화율 제한
degnin_heat, degnin_cool	누적 온도편차 x 시간	- 냉방/난방 부하 추정, 에너지 효율 분석	히터, 냉방 정책 평가

- AI 제어기의 예측-정책-결과 간 정합도 측정
- 실제 온실 제어정책 효과 검증 및 재학습 피드백 구성
- 최종적으로 이들 파생변수는 현재 환경 상태를 요약하는 상태벡터로 구성되어, AI 제어기 입력, 제어 정책의 백테스팅 등 여러 용도로 공통 활용되도록 설계함

3.3. 센서 데이터 보정 및 신뢰성 확보 구조

□ 센서 데이터 보정의 필요성

- 스마트온실 내부 센서 데이터는 제어 및 물리 파라미터 식별의 핵심 입력이 되나, 실제 현장에서는 센서 자체의 측정 오차, 노후화, 설치 편차, 환경 간섭 등으로 인해 상당한 불확실성을 내포함

- 특히 온·습도·일사 센서는 고온·고습·결로 환경에 장기간 노출되며, 초기 보정 이후 재교정이 이루어지지 않는 경우가 많아 절대값 정확도 및 장기 안정성 확보에 구조적 한계가 존재함
- AI 자율제어기 내부 센서 값 보정은 내부 센서 값을 무조건적인 진실값으로 가정하지 않고, 외부 기상대 데이터와의 비교 및 동적 시스템 관점의 센서 모델링을 통해 데이터 신뢰성을 검증·보정하는 구조를 채택함

□ 외부 기상대 데이터를 기준으로 활용하는 근거

- 외부 기상대 데이터는 다음과 같은 이유로 센서 검증을 위한 기준 데이터로 활용할 합리적 근거를 가짐
 - 계측 환경 및 관리 체계의 차이¹⁾: 기상대 관측 장비는 국제 표준(WMO 등)에 따른, 설치 기준, 정기 교정, 유지관리 체계를 통해 운영됨. 반면 스마트온실 내부 센서는 농가별 설치 위치·각도·차폐 조건이 상이하고, 장기 운영 중 교정 이력이 불확실한 경우가 대부분. 따라서 외기 온도·습도·일사량과 같은 기본 기상 변수에 대해서는 기상대 데이터가 장기적·통계적으로 더 안정적인 참조값으로 기능할 수 있음
 - 외기 환경의 공간적 대표성: 내부 센서는 국소 환경(팬 근처, 벽체 인접, 그늘 영역 등)의 영향을 크게 받는 반면, 기상대 데이터는 지역규모의 평균적 외기 조건을 대표함. 이는 온실 물리 모델의 외기 경계조건(Boundary condition)을 안정적으로 정의하고자 하는 목적에 부합함
 - 물리 파라미터 식별 관점에서의 정당성: 열손실계수(UA), 환기율(ACH), 열용량(C) 등 물리 파라미터는 내부 상태와 외기 조건 간의 동적 관계를 통해 식별됨. 이때 외기 입력이 불안정하거나 편향되어 있을 경우, 파라미터 식별 결과가 왜곡될 위험이 존재함. 기상대 데이터는 외기 조건의 시간적 추세와 일변화를 안정적으로 제공하므로, 물리 파라미터 식별을 위한 외기 기준 입력으로 활용하는 것이 구조적으로 타당함

□ 내부 센서를 동적 시스템으로 간주한 보정 접근의 정당성

- 내부 센서 수치를 보정하기 위해 내부 센서를 단순한 관측 장치가 아닌, 실제 환경 상태를 지연·왜곡·노이즈와 함께 관측하는 동적 시스템으로 해석함
- 내부 센서 측정값은 ①센서 자체 응답 지연, ②설치 위치에 따른 국소 열·습 환경 편차, ③결로·복사열·공기 정체 등 비이상적 환경 요인에 영향을 받음
- 따라서, 외부 기상대 데이터를 절대적 진실값으로 치환하는 것이 아닌, 외기 기준 신호(Reference)와 내부 센서 응답 간의 동적 관계를 모델링함으로써 센서 측정 오류의 구조적 특성을 식별·보정함

1) 경상북도 상주 실증단지 또한 기상대는 한국농업기술진흥원이 주기적인 관리를 함으로써 내부 센서보다 더 정확한 환경 정보 로그를 제공

□ 센서 데이터 보정 및 신뢰성 확보 구조

1) 목적 및 출력값 정의

- 스마트온실 내부 센서의 시계열 로그가 정상적인 동역학 범위 내에서 동작하는지를 통계적으로 검증하고, 이상치로 판단되는 시점에 한해 제한적 보정을 수행하여 제어기 입력에 적합한 안정적 상태벡터를 산출하는데 목적이 있음
- 입력 데이터는 내부 관측(보정 대상), 외부 입력(정상 범위 정의용), 제어 프록시의 세가지 종류의 데이터를 입력값으로 사용
 - 내부 관측: 내부 온도, 내부 습도, 내부 이산화탄소 농도
 - 외부 입력: 외기 온도, 외기 습도, 외기 일사, 외기 풍속, 풍향(참고용)
 - 제어 프록시: 팬, 천창 개도, 난방

2) 내부 온·습도 QC 보정

- 동역학 모델은 ARX(Autoregressive with exogenous inputs) 구조를 사용함. 내부 온도 또는 내부 습도 시계열을 공통적으로 y_t 라 정의하고, u_t 는 외기 입력 벡터라고 정의한다면,

$$y_t = \phi y_{t-1} + (1 - \phi)(\alpha + \beta^T u_t) + \epsilon_t, \quad \epsilon_t \sim N(0, \sigma_\epsilon^2)$$

$$u_t = [T_t^{out}, RH_t^{out}, I_t, \dots]^T$$

- $\phi \in (0, 1)$ 는 관성/완화 계수로, 직전 시점 값의 유지 정도를 나타냄
- 1-step 예측 평균과 예측 분포는 각각 다음과 같이 나타낼 수 있음

$$\mu_t := E[y_t | F_{t-1}] = \phi y_{t-1} + (1 - \phi)(\alpha + \beta^T u_t)$$

$$y_t | F_{t-1} \sim N(\mu_t, \sigma^2)$$

- 파라미터 추정은 ϕ 의 범위를 0과 1사이로 강제하기 위해 로짓 파라미터를 사용하고, 우도 기반 목적함수와 BFGS 알고리즘으로 최소화 하여 파라미터들을 산출함
- 예측구간 기반 정상성 판별(QC Flag)을 위해 유의수준 α_q (0.01를 기본값으로 설정)에 대해 양측 예측구간은 다음과 같음

$$L_t = \mu_t - z_{1-\alpha_q/2}\sigma, \quad U_t = \mu_t + z_{1-\alpha_q/2}\sigma$$

- 정상성 플래그는 다음과 같이 정의하고 NA/비유한 값을 포함한 시점에서 잘못된 판정이 발생하지 않도록 다음을 만족하는 경우에만 플래그를 계산함

$$Flag_t^{(uni)} = 1(y_t < L_t \vee y_t > U_t)$$

$$V_t = 1(finite(y_t, \mu_t, \sigma_t, L_t, U_t) \wedge \sigma > 0)$$

- 온도와 습도는 독립이 아니므로(습공기선도), 단변량 예측구간만으로는 결합적으로 비정상인 패턴을 식별하는게 불가능함. 그러므로 위에서 추정된 식의 잔차 벡터를 구성하여 Mahalanobis 거리 기반 검정을 추가함

- 잔차 벡터는 다음과 같이 구성하고 T는 온도, H는 습도로 정의함

$$e_t = \begin{bmatrix} e_t^{(T)} \\ e_t^{(H)} \end{bmatrix} = \begin{pmatrix} T_t^{obs} - \mu_t^{(T)} \\ H_t^{obs} - \mu_t^{(H)} \end{pmatrix}$$

- 잔차의 공분산을 추정후, Mahalanobis 거리 제곱을 계산, 정규성 가정 하에서 D_t^2 는 자유도 2인 카이제곱 분포를 따른다는 가정하에 다음을 적용

$$Flag_t^{(mv)} = 1(D_t^2 > X_{2, 1-\alpha}^2)$$

- 보정은 이상치로 판정된 시점에 한해 수행하며, 예측구간 밖으로 벗어난 값을 예측구간 안으로 제한하는 방식으로 보정함

$$y_t^{corr} = \begin{cases} \min(\max(y_t, L_t), U_t) & \text{if } Flag_t = 1 \\ y_t & \text{otherwise} \end{cases}$$

- 마지막으로 온실 운영 조건은 시간에 따라 변하는 문제가 있으므로, 단일 모델을 전체 기간에 고정하면 분포 변화에 문제가 생길수 있으므로, 윈도우 길이(W)와 이동간격(S)를 설정하여, 롤링 윈도우 적합-검정-보정을 수행하는 방식을 적용함

3) 내부 이산화탄소 QC 및 보정

- 현재 적용된 보정 기법은 온실 내부에 이산화탄소 발생기가 없고, 식물만 존재하는 환경을 가정으로 함
- 내부 이산화탄소는 환기/침기 및 주야 생리(광합성/호흡)에 의해 변화하므로 정상 변화 패턴(동역학 범위)에서 벗어나는 시점의 탐지, 해당 시점의 제한적 보정을 수행함
- 이산화탄소 변화량 모델은 이산화 탄소 변화량 계산 후 확률 모델을 다음과 같이 정의함

$$\Delta C_t = \beta_0 + \beta_1(C_{t-1} - C^*) + \gamma^T x_t + \epsilon_t, \quad \epsilon_t \sim N(0, \sigma^2)$$

- 여기서 C^* 는 외부 이산화탄소를 직접 알 수 없을 때 윈도우 내 유효 평형점으로 추정되는 상수
- 추정은 가우시안 오차 가정으로, 음의 로그우도를 최소화하여 추정하고 윈도우 내 샘플이 충분할 때만 적합함. 다음과 같이 두 식을 계산

$$\Delta \hat{C}_t = \hat{\beta}_0 + \hat{\beta}_1(C_{t-1} - \hat{C}^*) + \gamma^T x_t$$

$$\mu_t^{(C)} = C_{t-1} + \Delta \hat{C}_t$$

- 온·습도와 동일하게 예측분포를 두고 예측 구간을 구성함

$$C_t | F_{t-1} \sim N(\mu_t^{(C)}, \sigma^2)$$

$$L^{(c)} = \mu^{(c)} - z_{1-\alpha_q/2}\sigma, \quad U^{(c)} = \mu^{(c)} + z_{1-\alpha_q/2}\sigma$$

- 보정은 클리핑으로 동일하게 적용

$$C_t^{corr} = \begin{cases} \min(\max(C_t, L_t^{(c)}), U_t^{(c)}) & \text{if } Co2\ QCflat_t = 1 \\ C_t & \text{otherwise} \end{cases}$$

- 온·습도와 동일하게 롤링 윈도우(W, S) 적용

□ 물리식 사용이 아닌 통계적 접근의 정당화

- 물리식 기반 모델은 열수지, 수분수지, 이산화탄소 질량수지 등을 통해 온실 환경 상태를 정밀하게 예측·재현하는데 강점을 가짐
- 그러나 본 데이터 보정의 목적은 환경 상태의 정확한 추정이 아닌, 센서 관측값이 정상적인 동역학 범위 내에서 생성되었는지를 판별하는데 있음
- 실제 스마트온실 현장에서는 단열계수, 체적, 열용량, 환기량(ACH), 유효 개도면적, 장비 효율 등 핵심 물리 파라미터가 부재(데이터 부재) 하거나 불확실성함. 이러한 조건에서 물리식 기반 보정을 적용할 경우, 모델 파라미터 오차가 센서 측정 오차로 흡수되는 문제가 발생할 수 있음. 이로 인해 센서 고장이나 스파이크 현상이 물리 파라미터 변화로 잘못 해석되는 식별 혼동 위험성을 가짐
- 온실 내부 환경은 난방, 환기, 차광 등 제어 입력을 받는 환경이며, 물리식 적용을 위해서는 이러한 제어 입력의 출력, 효율, 응답 지연, 공간적 분포까지 정량화하여 모델에 포함시켜야함
- 이는 센서 신뢰성 검증이라는 목적을 넘어, 디지털트윈 구축 문제로 연구 범위를 확장시키는 단계에서의 접근법으로 본 연구에서는 제어 입력을 완전하게 모델링하지 않더라도, 예측분포 기반 경계 밖 탐지를 통해 센서 이상 판별 목적을 달성할 수 있음
- 물리식 기반 보정은 모델이 실제 환경과 불일치 할 경우, 센서 데이터 전체를 지속적으로 잘못된 방향으로 왜곡할 위험성을 가지고 있음. 하지만 통계적 접근법은 이상치로 판별된 시점에 한해서만 보정을 수행하며, 보정 범위는 예측구간 내로 제한되는 방법을 사용하여 모델 오차가 존재하더라도 보정의 영향이 국소적으로 제한되도록 설계함
- 그 결과 제어기 입력을 과도하게 변형하지 않으면서 운영 안정성과 데이터 신뢰성을 동시에 확보 가능

3.4. 물리 파라미터 식별 방법

□ 단일 구획 모델

- 스마트온실의 구조적·물리적 특성을 직접 측정하거나 설계도·장비 제원을 확보하기 어려운 현실적 한계를 고려하여, 본 연구는 실측 환경 로그를 입력으로 하여 열손실계수(UA), 유효열용량(C), 환기율(ACH), 일사 유효계수(η)를 역산·추정하는 단일 구획 모델 기반 식별 방식을 적용함
- 식별된 파라미터는 단순 파생변수가 아닌 스마트온실의 열·광·환기 반응을 설명

- 하는 동적 시스템의 응답 계수로 활용되며, AI 자율제어 모델에서 예측 안정성 확보(온도 반응 지연, 히터 효과 편차 보정), 물리적 제약 준수(결로·과열·환기·손실 관리), 에너지 소비 효율화(히터·차광·환기 조합 최적화)의 핵심 근거로 사용
- 물리 파라미터 식별은 실측 로그의 정보량이 높은 구간(예: 야간 무일사, 히터 작동/미작동 스텝 반응 구간, 환기 개도율 급변 구간)을 우선적으로 활용하여 신뢰성 높은 초기 추정치를 도출하고, 여름/겨울 계절 변화, 피복 노후화, 장비 성능 저하 등에 따른 Drift 발생 시에는 몬테카를로 시뮬레이션 기반 보조 추정 및 후속 재식별 절차를 반복 수행함으로써, 시간에 따라 변화하는 온실의 물리 특성에 적응하는 AI 정책 구조를 구현함

□ 단일 구획 모델 기반 기본식

- 스마트온실의 열환경은 시간에 따라 변하는 비정상 에너지 평형으로 표현할 수 있으며, 내부 공기의 온도는 외기 환경, 일사, 난방, 환기, 구조물의 단열 특성 등 다중 요인에 의해 결정됨
- 이러한 열·질량 교환 과정은 다음과 같은 에너지 보존식으로 표현할 수 있음

$$C \frac{dT_{\in}}{dt} = Q_{heat} + \eta I_t A - UA(T_{\in} - T_{out}) - \rho c_p ACH \frac{V}{3600} (T_{\in} - T_{out})$$

기호	설명	단위	산출 또는 추정 방식
T_in	온실 내부 공기 온도	° C	실측 센서 로그
T_out	외기 온도	° C	기상 관측 로그
I_t	순간 일사량	Wm ⁻²	광센서 또는 일사계
Q_heat	히터 공급열량	W	히터 출력 x 가동률
A	온실 외피면적	m ²	설계도 기반 상수
V	온실 체적	m ³	구조 제원 기반 상수
C	유효 열용량	JK ⁻¹	식별 대상
UA	열손실계수	WK ⁻¹	식별 대상
η	일사 유효계수		식별 대상
ACH	환기율	h ⁻¹	식별 대상
ρ c_p	공기 밀도 및 비열	1.2 kg m ⁻³ , 1005Jkg ⁻¹ K ⁻¹	상수로 사용

(1) 내부 열축적항

- 단위 시간당 내부 공기에 축적되는 에너지량으로, 온실 내 온도 변화의 관성(inertia)를 나타냄
- 공기·피복재·작물체·배관 등의 질량과 비율의 합성값으로 정의
- 야간 무일사($I_t = 0$) 구간에서 히터의 켜/꺼 신호와 내부 온도 상승률을 이용하여 C를 회귀식으로 역산
- 제어기 예측 시 온도응답 지연을 반영하고, 히터·환기 정책 간 상수(drift) 조정에 활용

(2) 히터 입력항

- 외기 열손실 및 환기 손실을 보상하기 위해 공급되는 외부 에너지
- 히터 출력(상주 온실 기준 10,000kcal/h) x 동작률(%)로 산출하거나, 제어 신호와 정격출력을 곱하여 근사

(3) 일사 유입항

- 외부 일사가 피복을 통과하여 내부로 전달되는 유효 태양복사 에너지
- 피복 투과율(τ)과 내부 흡수율(α)의 곱으로 표현되며, 차광 커튼 개폐율에 따라 동적으로 변함
- 맑은 하늘(가정) 주간구간에서 실측 내부온도 상승률과 외기일사량으로 회귀분석을 수행하여 추정
- 광환경-열환경 균형 제어의 기준으로, 과열 방지를 위한 차광·환기 정책의 정량화에 사용

(4) 전도·복사 손실항

- 내부와 외기 사이의 전도·복사에 의한 열손실량
- U: 단위면적당 열전달계수($Wm^{-2}K^{-1}$), A: 피복재 전체 면적(m^2)을 상수로 하여 일사·환기 영향이 없는 야간 시간대에 내부온도와 외기온도, 그리고 히터 입력항을 이용한 1차 회귀로 추정
- 단열성(Thermal insulation)을 수치화한 지표로, UA가 커질수록 열손실이 커짐
- 난방에너지 소비량 예측 및 에너지 절감 정책의 검증에 직접 사용함

(5) 환기 손실항

- 외기와의 공기 교환으로 발생하는 열손실량으로, 환기율(ACH)이 증가할수록 냉각 효과가 커짐
- 환기장 개도율 및 외기풍속을 설명변수로 한 다중회귀 또는 비선형 회귀로 추정
- AI 제어기에서 환기 열손실 위험을 제한하여 차광·난방 정책 간 균형을 유지하는

□ 단일 구획 모델 회귀 기반 식별 방법: 데이터가 충분할 경우

- 스마트온실 내부 열환경을 공기·구조물·작물체·유량계통 등을 하나의 가상 열용량(C)을 가진 단일 열질량(Termal mass)으로 단순화하여, 시간에 따른 내부 온도 변화를 외기 조건의 변화, 일사 입력, 난방 공급, 환기 손실의 네 가지 주요 원인에 의한 결과로 표현함
- 이는 기존 모델링이 요구하던 피복재 정보, 면적, 난방 용량 등 설계 제원이 제공되지 않는 농가 현장의 현실을 고려하여, 실측 센서 로그만을 이용하여 온실 고유의 동특성을 직접 연산하기 위해 설계됨
- 스마트온실은 외부 기상 조건의 급격한 변동, 피복재 노후화에 따른 단열 성능 저하, 장비 출력 변화와 같은 복잡한 불확실성을 포함하며, 이러한 요소는 시간에 따라 변화함. 이러한 변화를 실측 로그에 반영된 반응성 변화로 간주하고, 이를 주기적으로 재식별함으로써, 정적 모델이 아닌 동적 환경 적응형 물리 파라미터를 제공하도록 설계하여 AI 제어기가 지속적으로 시설 노후화와 계절 조건에 적응할 수 있도록 함

(1) 입력 로그 전처리 및 표준화

- 물리 파라미터는 모델에서 정의되는 값이 아니라, 데이터가 보여주는 반응에서도 출되기 때문에 전처리 과정은 단순한 데이터 정리가 아니라 물리 반응을 추출하는 단계
- 전처리 과정에서 전원 상실(PLC blackout) 또는 PLC 오류 등 내부 제어기 이상 신호는 학습 대상에서 제외
- 온도 센서의 순간 점프(약 4°C 이상/10분 이내)는 계산 과정에서 차분시 큰 왜곡을 일으키므로 제거
- 조도·일사 센서는 여러 기준이 혼재할 수 있으므로, 일사 환산식을 통해 모두 W/m2로 표준화

(2) 반응 함수 정의

- 스마트온실 시스템의 물리적 특성은 온도 절대값보다 온도가 얼마나 빠르고 어떤 방향으로 변화하는가가 중요하기 때문에 반응 함수는 다음과 같이 정의

$$y_k = \frac{T_{in}(k+1) - T_{in}(k)}{\Delta t}$$

- 차분 과정에서 발생하는 단기 노이즈는 중심이동평균(Centered moving average)로 완화하며, 외기 급변 시 스무딩 폭을 축소 하여 물리적 반응성 보존을 우선시 함

- 이 단계의 목적은 계측 잡음(Noise)을 줄이면서, 온실 시스템이 에너지 압력·손실에 어떻게 반응하는지를 최대한 보존하는 것

(3) 설명 변수(Feature) 구성 및 물리적 해석

- 본 모델에서 온실 내부 온도 변화 원인은 네 개의 독립적인 물리 입력항으로 표현함
 - 히터에 의한 외부 열 공급
 - 일사에 의한 복사 에너지 공급
 - 내외 온도차에 따른 전도·복사 열손실
 - 환기 개도 및 온도차에 의한 대류 열손실
- 환기 손실은 온도차가 존재할 때만 발생한다는 열역학적 원리에 기반하여 정의되며, 이는 자연 대류와 강제 대류를 하나의 근사식으로 통합한 형태
- 이렇게 정의된 네 개의 입력 항은 이후 회귀 모델에서 각각 히터 효과, 일사 효과, 단열 손실, 환기 손실에 해당하는 계수로 추정되어 각각의 물리 파라미터들과 직접적으로 매핑됨

(4) 학습 구간 선택

- 식별하고자 하는 물리 파라미터들은 물리적 신호가 충분히 발생한 시간대에서 식별 가능
 - 열손실계수(UA)는 히터 미작동·천창 미작동·외기가 안정적인 구간에서 식별 가능
 - 유효열용량(C)는 야간·무일사·히터 미작동/작동 스텝에서 식별 용이
 - 환기율(ACH)는 환기 개도를 변화가 명확하게 발생하는 구간에서 식별 용이
 - 일사 유효계수(η)는 맑은 주간·커튼 고정 구간에서 식별
- 이와같이 본 방법은 전체 로그를 단순히 통계적으로 추정하는 방식이 아니라, 물리 반응이 발생한 부분만 선별적으로 학습에 투입하는 방식을 사용함

(5) 회귀 모델과 계수 해석

- 단일 구획 모델은 내부 온도 변화율을 히터, 일사, 내외 온도차, 환기 개도 및 온도차 네 가지 항의 선형 결합으로 표현하고 이 때 각각의 계수는 히터 효과, 일사 효과, 단열 손실, 환기 손실에 해당하며, 회귀 계수에 유효열용량(C)를 곱하거나 나누는 방식으로 실제 물리 파라미터로 환산할 수 있음

$$y = \frac{k_{heat}}{C}X_1 + \frac{\eta}{C}X_2 - \frac{UA}{C}X_3 - \frac{k_{vent}}{C}X_4 + \epsilon$$

$$\begin{aligned}
X_1 &= \text{heater signal} \\
X_2 &= \text{Radiation} \\
X_3 &= T_{\in} - T_{out} \\
X_4 &= Vent_{open} \times (T_{\in} - T_{out})
\end{aligned}$$

- 회귀 학습에는 일반 최소제곱(OLS) 대신 Huber 회귀를 사용하여, 히터 작동/미작동 전환, 환기 개도 급변, 강풍 유입 구간에서 발생하는 일시적인 큰 잔차에 선형 패널티를 부과하여 큰 오차의 영향을 완화하여 센서 오류나 일시적인 제어 이상에 덜 민감한, 보다 안정적인 파라미터 추정이 가능

$$L_{\delta} = \begin{cases} \frac{1}{2} r^2 & \text{if } |r| \leq \delta \\ \delta (|r| - \frac{1}{2}\delta) & \text{otherwise} \end{cases}$$

- 유효열용량은 직접 회귀로 추정할 수 없으므로, 시뮬레이션 기반 단일 변수 최적화를 사용. 목표 함수는 다음과 같음

$$C_{est} = \arg \min \|T_{sim}(C) - T_{obs}\|^2$$

- 목표 함수에서 회귀식으로 얻은 파라미터 비율을 고정한 상태에서 C만을 변경해 가며 시뮬레이션을 수행하고, 시뮬레이션 결과와 실측 내부 온도 시계열 간의 오차가 최소가 되는 C를 찾는 방식으로 추정함. 이때 최적화는 미분 정보를 요구하지 않은 L-BFGS-B 또는 단순 Grid Search로 수행하여 물리 모델이 부분적으로 비선형이거나 미분 가능성이 낮은 구간이 포함되더라도 안정적으로 추정할 수 있도록 함

(6) 파라미터 환산과 AI 제어기의 정책 적용

- 환기·단열 손실에 대한 물리식은 다음과 같이 단순화 가능

$$\begin{aligned}
Q_{loss, vent} &= K_{vent} \times (T_{in} - T_{out}) \\
Q_{loss, cond} &= UA \times (T_{in} - T_{out})
\end{aligned}$$

- 따라서 AI 제어 정책 탐색 시 다음과 같은 형태의 제약식으로 표현 가능
 - 히터가 작동중인 상태 + 천창이 열린 조건에서 $Q_{loss, vent} + Q_{loss, cond} > \text{설정 임계값}$ 일 경우, 정책 후보군에서 제거
 - 예를 들어, 난방 작동 상태에서 환기 개도율과 내외 온도차가 클 경우, 환기에 의한 열손실 $Q_{loss, vent}$ 가 일정 임계값을 초과하면 해당 제어 조합은 정책 탐색 공간에서 제외되도록 설계할 수 있으며, 이를 통해 물리적으로 비효율적이거나 위험한 정책(예: 강한 난방과 강한 환기를 동시에 사용)을 사전에 차단함

(7) 경상북도 혁신벨리 16번 실증온실 물리 수식 식별 결과

- 유효열용량(C)은 약 $100,000 \text{ J} \cdot \text{K}^{-1}$ 수준으로 추정되며 이는 내부 공기만을 고려한 열용량 $1.2 \times 10^3 \text{ J} \cdot \text{K}^{-1}$ 보다 약 80배 이상 큰 값으로 바닥과 금속 구조체, 피복재, 내부 설비가 열 저장 매스로 작동하고 있음을 의미함. 이 값은 일반

적인 비닐 온실의 열용량 범위를 상회하는 수치로 온실 전체가 열 완충체로 기능하고 있음을 의미함

- 히터에 의한 열 공급 효과를 나타내는 k_{heat} 은 약 $2.94 \times 10^4 \text{W}$ (제어 신호 단위당 열공급효과) 수준으로 산출되었으며, 이는 난방 제어 신호의 단위 변화가 온도 상승에 빠르게 반영됨을 의미함
- 일사 열공급 효율을 나타내는 η 는 약 $2.08 \times 10^{-2} \text{W} \cdot \text{m}^{-2}$ 수준이며, 난방 효과 대비 기여도가 낮아 겨울철 자연 복사만으로 온도를 유지하기 어려운 수준임. 반면 일사량이 높아지는 봄철에는 일사만으로 열 공급이 충분하거나 과열 방지 정책이 필요
- 구조적 열손실 계수(UA)는 약 $3.55 \times 10^3 \text{W} \cdot \text{K}^{-1}$ 으로 추정, 이는 실내외 온도가 1K당 매 시각 약 3.55kW의 열손실이 발생함을 의미하며 온실의 단열 성능이 단층 비닐 온실(U 값 $6 \sim 8 \text{W} \cdot \text{m}^2 \cdot \text{K}^{-1}$)에 비해서는 열손실이 큰 편에 속함
- 환기 개방에 따른 추가 열손실을 나타내는 K_{vent} 는 약 $7.48 \times 10^3 \text{W} \cdot \text{K}^{-1}$ 이며 이는 구조적 단열 손실 계수보다 약 두 배 정도 큰 영향력을 가짐. 이는 환기 개도율과 실내 온도차가 함께 존재할 경우 급격한 열손실이 발생할 수 있음을 의미하며 자연환기형 비닐 온실에서 관측되는 환기 손실 수치와 유사한 수치($5.0 \times 10^3 \text{W} \cdot \text{K}^{-1}$)

□ 단일 구획 모델 회귀 기반 식별 방법 일반화: 데이터 수치가 제한적일 경우(관측 1달 이상 수집 권고)

- 단일 구획 모델 기반 식별 방법은 내부 온도 변화율을 히터, 일사, 내·외기 온도차, 환기 개도율 등 네 개의 설명변수로 선형 회귀하고, 이후 회귀 계수와 열용량 C간의 비율 관계를 이용하여 물리 파라미터를 역산하는 방식을 사용함
- 이 방식은 식별에 필요한 구간(야간 무일사, 히터 스텝, 환기 스텝, 맑은 주간 등)이 충분히 존재하는 경우 비교적 안정적인 결과를 제공하지만 ① 한달 단위의 장기 로그에서 히터·환기·일사 패턴이 고르게 분포하지 않은 경우, ② 환기 개도율과 구조적 열손실이 모두 외·내기 온도 차분에 비례하는 항으로 나타나기 때문에, 회귀식만으로는 UA와 K_{vent} 를 분리하기 어려운 구조적 식별 한계, ③ 히터/환기 구간이 짧거나, 센서 노이즈·제어 이상·외기 급변이 혼재된 경우, 회귀 기반 $\frac{dT_{\text{e}}}{dt}$ 추정이 불안정해지고, 결과적으로 물리 파라미터가 비현실적으로 수렴할수 있는 한계점들을 가지고 있음
- 특히 면적만 알고 있고, 피복 정보·정확한 난방 용량 등 설계 제원이 제한적인 것 뿐만 아니라 스마트온실 장비 설치 후 가용 데이터가 적다는 현장 상황에서는, 데이터 패턴에 과민하거나, UA와 K_{vent} 등 상관계수가 높은 항을 잘못 분해하는 위험이 있음

- 단일 구획 모델 기반 기본식이 시간에 따라 변하는 비정상 에너지 평형으로 표현하는 열질량 모델로 단순화 한다면, 에너지 보존식은 다음과 같이 표현됨

$$C \frac{dT_{\epsilon}}{dt} = Q_{heat}(t) + Q_{solar}(t) - Q_{loss, struct}(t) - Q_{loss, vent}(t)$$

- 여기서 히터 공급열량, 일사 유입열량, 구조적 전도·복사 손실, 환기 손실 각각의 항은 다음과 같이 표현됨

$$Q_{heat}(t) \simeq k_{heat} H_t$$

$$Q_{solar}(t) \simeq \eta I_t$$

$$Q_{loss, struct}(t) \simeq UA(T_{\epsilon}(t) - T_{out}(t))$$

$$Q_{loss, vent}(t) \simeq K_{vent} V_t(T_{\epsilon}(t) - T_{out}(t))$$

- 따라서, 모델의 기본 미분 방정식은 다음과 같음

$$\frac{dT_{ln}}{dt} = \frac{1}{C} (k_{heat} H_t + \eta I_t - UA(T_{ln} - T_{out}) - K_{vent} V_t(T_{ln} - T_{out}))$$

- 제한된 정보(면적)를 가지고 단일 구획 모델 시뮬레이션 기반 자동 식별을 위해 내부 온도 변화율을 회귀로 적합하는 대신, 전체 온도 시계열을 직접 수치적으로 적분하여 실측 $T_{ln}(t)$ 궤적과 시뮬레이션 $T_{ln}^{\sim}(t)$ 간의 오차를 최소화하는 방향으로 파라미터 $\theta = (C, K_{heat}, \eta, U, A, K_{vent})$ 를 자동 조정하는 방식을 사용함
- 이때 온실 면적, 피복 종류와 같은 제한된 설계 정보를 활용하여 C와 UA에 대한 사전 범위(prior range)를 계산하고, 모든 파라미터는 이 범위 내에서 수치 최적화를 통해 자동으로 조정함. 단계별 절차는 다음과 같음

(1) 입력 로그 전처리 및 표준화

- 단일 구획 모델 기반 식별 방법의 입력 로그 전처리 및 표준화 방법을 그대로 적용
- 시간 간격 계산을 위해 인접 로그 시간 차이를 계산하고, 시간 단위로 변환(예: $dt_{hr} = dt_{sec} / 3600$)
- 10분 간격을 기준으로 하되, 실제 로그 간격이 약간 변동될 수 있으므로, 실제 dt_{hr} 를 그대로 사용하여 수치 적분 시 반영

(2) 단일 구획 동역학 모형 및 수치 적분

- 앞서 정의한 에너지 보존식을 이산 시간 t_i (10분 간격)에서 오일러 근사로 적분 하면

$$T_{\epsilon}^{\sim}(t_{i+1}) = T_{\epsilon}^{\sim}(t_i) + \frac{\Delta t_i}{C} (k_{heat} H_{t_i} + \eta I_{t_i} - UA(T_{\epsilon}^{\sim}(t_i) - T_{out}(t_i)) - K_{vent} V_{t_i} (T_{\epsilon}^{\sim}(t_i) - T_{out}(t_i)))$$

- 첫 시점에서 $T_{\epsilon}^{\sim}(t_1) = T_{\epsilon}^{obs}(t_1)$ 으로 설정하여, 모델과 실측 시계열이 동일한 출발

점에서 시작하도록 함. 그 후 전체 데이터에 대해, 위 식을 시계열 길이만큼 순차적으로 적분하여, 시뮬레이션 값을 생성

(3) 파라미터 벡터 및 탐색 공간 설정

- 최적화 대상의 파라미터 벡터는 $\theta = (C, K_{heat}, \eta, U, A, K_{vent})$. 온실 면적 A와 피복 종류를 이용하여 C와 UA에 대한 사전 추정값(prior)과 탐색 범위(bound) 계산
- 구조적 열 손실계수는 피복 종류별 대표 U 값 U_{base} (예: 유리 구조일 경우 $5W \cdot m^{-2}K^{-1}$)를 가정하고 다음 수식에서 탐색 범위 UA 계산

$$UA_{prior} = U_{\Delta} A$$

$$UA \in [0.3 UA_{prior}, 3.0 UA_{prior}]$$

- 유효열용량은 공기 기준 열용량 $C_{air} = \rho c_p V$ 계산 후(온실 체적 V x 평균 높이) $C_{prior} = 3C_{air}$ 로 정의하여 공기, 구조체, 바닥의 합성 열질량을 반영 후 다음과 같이 정의된 탐색 범위안에서 계산

$$C \in [0.3 C_{prior}, 5.0 C_{prior}]$$

- 난방 계수 k_{heat} , 일사 계수 η , 환기 계수 K_{vent} 는 UA_{prior} 를 기준으로 대략적인 스케일을 설정하여 넓은 범위에서 탐색을 가능하게 함(예: $k_{heat}, prior \approx 10UA_{prior}$, $\eta_{prior} \approx 0.1UA_{prior}$ 등)
- 모든 파라미터는 물리적으로 의미 있는 부호 제약을 갖도록 설계함

$$C > 0$$

$$UA > 0$$

$$K_{heat} \geq 0$$

$$\eta \geq 0$$

$$K_{vent} \geq 0$$

(4) 목적 함수 정의

- 시뮬레이션 기반 자동 식별 목적은 모형이 생성한 내부 온도 궤적이 실측된 가용 데이터 궤적을 얼마나 잘 재현하는가를 기준으로 파라미터를 자동 조정하는 것임
- 기본 목적함수는 평균제곱오차(MSE)를 사용하고, 선택적으로 면적 기반 prior에 대한 연성 제약을 걸기 위해 C와 U에 대한 패널티 항을 추가함

$$L(\theta) = MSE(\theta) + \lambda_c (C - C_{prior})^2 + \lambda_{UA} (UA - UA_{prior})^2$$

- 여기에서 λ_c, λ_{UA} 는 prior를 어느 정도 신뢰할지에 대한 하이퍼파라미터로, 데이터가 해당 파라미터에 대해 충분한 정보를 제공하지 못하는 경우 값이 비현실적으로 치우치는 것을 방지하는 역할을 함

(5) 최적화 알고리즘: 다중 시작점 기반 L-BFGS-B

- 목적함수가 비선형적, 파라미터들간의 상관성이 높은 특성으로 인해 국소 최소값(Local minimum)이 존재할 수 있는 가능성이 있으므로, L-BFGS-B 알고리즘을

사용하여 최적화를 진행함

- L-BFGS-B 알고리즘은 파라미터별 상·하한을 직접 지정할수 있으며, 면적 기반으로 정의한 C, UA 범위와 k_{heat} , η , k_{vent} 물리적 범위를 그대로 반영 가능
- 면적 기반 prior를 중심으로 로그-정규 분포를 적용하여 여러 개의 초기 파라미터 세트를 생성. 각 초기값에서 L-BFGS-B 최적화를 수행하고 $L(\theta)$ 가 가장 작은 해를 최종 식별 결과를 채택
- 또한, 회귀식으로 미리 파라미터를 정해두지 않고 전체 가용 데이터 궤적을 기준으로 모든 파라미터를 동시에 자동 조정함으로써 부분 구간 회귀에 의존하는 방식의 불안정성을 줄임

(6) 식별 파라미터의 물리적 해석 및 AI 연계

- 식별된 파라미터 $C, K_{heat}, \eta, U, A, K_{vent}$ 각각 온실 전체 유효 열용량, 히터 제어 신호당 실효 열 공급량, 일사 입력에 대한 유효 열 변환 효율, 구조적 전도·복사 열손실 계수, 환기 개도율과 온도차에 따른 대류 열손실 계수로 ①유효열용량: 외부 제어 신호에 대한 내부 온도의 관성(inertia)과 반응 지연 정량화, ② 야간·무일사 조건에서 난방 제어가 온도 유지에 미치는 영향, ③ 광환경-열환경 균형 제어 및 차광 정책 설계 기준, ④ 난방 에너지 소비량 예측 및 단열 개선 효과 평가 지표, ⑤ 난방과 환기 동시 사용 시 에너지 비효율을 정량화하고, AI 제어기에서 난방과 환기 과개방 조합을 제약하는 근거로 사용

□ 파생변수 및 물리 파라미터의 AI 제어기 적용 구조

- 스마트온실 AI 자율제어 시스템은 단순한 센서 기반 제어기를 넘어, 온실 내부에서 발생하는 열·수분·광·환기 상호작용을 물리·생리적으로 해석한 파생변수와 온실 구조적 특성을 반영한 물리 파라미터를 함께 활용하여 안전제약·제어결정·정책보정이 가능하도록 설계함
- 이는 기존 AI 온실 제어기(Ver2.5 이하)에서 결여되어 있던 해석 계층(Interpretation layer)을 제공하여 관측값이 지닌 물리적 의미를 정책 판단에 그대로 반영할 수 있게 하는 핵심 구조임

(1) 적용 구조 개념

- AI 제어기는 실시간 관측값을 직접 정책 입력으로 사용하지 않고, ①환경 관측(센서), ② 파생변수 산출(생리·광·안전 해석), ③물리 파라미터 적용(시설 반응 특성 반영), ④ 제어 한계·안전 제약 생성, ⑤제어 정책 생성 및 실행, ⑥ 일일 성능 기반 정책 자동 보정의 다층 구조를 통해 제어 결정을 내림

(2) 파생변수의 기능적 역할과 적용 구조

- 파생변수는 온도·습도·광·풍속·일사량 등 1차 센서값에서 직접 파악하기 어려운 물리·생리 상태를 정량화한 값으로 AI 제어기의 판단기준과 안전 제약을 구성함
- (생리·결로 안전 변수) VPD, 이슬점, 이슬점 여유, 과습 누적지표, 결로 예보치와 같은 변수들은 작물이 실제로 느끼는 생리적 스트레스와 결로 위험을 정량화함
- 이 변수들은 **환기 최소량 설정**(과습·저VPD 상태가 누적될수록 최소 환기량이 자동으로 증가하여 병해·결로 위험이 높은 조건에서 환기 부족이 발생하지 않도록 함), **환기창의 최대 개도 제한**(결로 발생 임계에 접근하거나 단기 예보에서 결로 위험이 감지되면 환기창이 과도하게 열려 내부 온도가 급격히 떨어지지 않도록 자동 제한), **열보온 커튼의 폐쇄 한계 조정**(환기 통로를 보장해야할 경우 커튼이 완전히 닫히지 않도록 상한 자동 설정)의 세 가지 기능을 수행. 즉, 생리적 안전과 결로 회피는 별도의 제어 규칙이 아닌 파생변수 기반의 동적 한계치(Dynamic Safety Constraints)로 실시간 반영됨
- (광·에너지 균형 변수) DLI, 청천 대비 누적광 비율, 목표광 도달 예상 시간 등은 온실 내부의 광환경을 에너지적 관점에서 해석하는 데 사용함
- 이 수치들은 **커튼 개폐 정도 조절**(실측 누적광이 목표보다 부족할 경우, 커튼 개방을 우선하도록 하고, 일사가 과다하거나 과열이 증가하는 구간에서는 차광 비율을 증가시킴), **광확보·온도 안정성 균형 조절**(목표광 도달 시간을 예측하여 일사가 충분히 확보될 때까지는 개방을 유지하고, 이후에는 과열 방지 정책으로 전환하는 방식의 시간 최적화를 적용)
- (물리적 제약 변수) 내·외기 온도차, 최소 환기율, 개도율 변화 한계, 부하량 지표는 온실이 물리적으로 감당할 수 있는 범위를 제어기에 제공
- 이 변수들은 **환기량 하한**(최소 환기율 유지), **개도율 변화 속도 제한**(램프율 제약), 기상 조건 기반 개도율 상한(풍속·강우 시 제한)의 역할을 수행
- 제어기는 어떤 정책을 선택하더라도 물리 한계를 벗어나는 명령이 자동 차단되는 구조로 동작함

(3) 물리 파라미터의 AI 제어기 적용 구조

- 물리 파라미터(열손실계수, 유효열용량, 환기율 모델 계수, 일사 유효계수 등)는 온실 구조·장비 특성에 따른 반응 차이를 보정해주는 역할을 함
- 이는 단순 설명용 수치가 아니라, 제어기가 환경 변화를 해석하는 기준값으로 기능함
- (열응답 해석) 온실 내 모든 열질량을 하나의 등가 열용량(C)으로 정의하고, 구조·피복 상태를 열 손실계수(UA)로 나타냄
- (온도 변화 응답성 해석) 동일한 난방·환기 조건에서 온도 변화가 빠른 시설, 느

린 시설을 구분하여 제어 민감도를 조정하는 기준으로 작용

- (예측 안정성 확보) 열관성(C)이 큰 시설에서는 개도율 변화 대응을 보수적으로 조정하고, 열손실계수(UA)가 큰 시설에서는 과도한 환기로 인한 온도 급강하 위험을 더 크게 반영
- (환기 반응 해석: 환기율 모델) 환기창 개도율·외기 풍속을 환기량(ACH)으로 변환하는 모델이며, 온실마다 기하구조·개구부 형태가 다르게 때문에 별도의 식별 과정이 필요함
- 제어기에서는 얼마나 개도를 할 것인가가 아닌 환기를 얼마나 할 것인가 기반의 판단으로 최소 환기량 계산 후 개도율을 역산하고, 결로·저VPD 상황 시 환기량 목표를 직접 보정하는 방식으로 작동함
- (일사-온도 상호작용 해석:일사 유효계수) 일사량이 내부 온도 미치는 실제 영향 (피복 투과·흡수·반사 포함)을 의미하며, 이는 과열 가능성 판단과 차광 정책의 기반이 됨
- 일사(w/m2) 증가 시 내부 온도 상승률 해석
- 차광·환기 조합의 효과를 온도 변화와 연결
- 광 확보 정책과 열 안정 정책 간의 균형 판단

(4) 파생변수·물리 파라미터 기반 제어 구조 특징


- AI 제어기는 파생변수·물리 파라미터를 다음과 같은 3가지 방식으로 구조화하여 활용함. ① 생태 해석 계층(Interpretation Layer): 센서값을 물리·생리적 의미로 해석하여 제어기의 현재 상태 인식을 정량적 체계로 나타냄. ② 동적 제약 계층(Dynamic Constraints Layer): 파생변수와 물리 파라미터는 모두 제어 가능 범위와 안전 한계를 실시간으로 설정하는 데 목적이 있음. 이 계층은 정책 모듈과 독립적으로 항상 적용되기 때문에 어떤 정책 로직이 동작하더라도 물리적 안정성을 보장함. ③ 평가·보정 계층(Evaluation @ Tuning Layer) 일일 온도 커버리지·평균편차(mdev), 누적 부하량 등은 정책의 성능 평가와 자동 보정의 기준으로 사용함. 물리 파라미터는 시설의 계절 변화·노후화 감지에도 활용되어 장기적으로 안정적인 제어 성능을 제공하기 위함으로 설계됨

3.5. AI 자율제어 정책 설계 및 보정 구조

□ AI 자율제어기 전체 모듈 아키텍처

- AI 자율제어기는 단순 규칙 기반 제어기가 아닌 ① 실시간 데이터 수집, ② 파생변수·상태벡터 생성, ③ 물리 파라미터 반영, ④ 작물·상태 기반 목표 생성, ⑤ 제어후보 전략 산출²⁾, ⑥ 안전·물리 제약에 따른 필터링, ⑦ 최종 제어 명령 출력, ⑧ 일일 성능 기반 정책 보정의 일련의 프로세스를 거쳐 작동함

- **실시간 제어 루프**는 센서 정보와 파생변수를 이용해 온실의 현재 상태를 해석하며, 물리 파라미터(열손실계수, 열용량, 일사 유효계수, 환기율 모델 등)를 활용해 제어 동작의 단기적 열적·광적 효과를 예측
- **정책 기반 제어**는 주·야간 목표 온도의 기본값에 정책 편차(Bias)를 더해 결정됨. 온도 오차는 데드밴드(Dead-band)와 P-band(Proportional band)에 의해 정규화되어 제어 강도로 변환되며 환기·난방·커튼 등의 제어 조합은 안전 제약과 물리 제약을 반영해 제한됨
- 하루 동안의 주·야간 체류율, 평균 온도 편차, 제약 위반 정도를 평가하여 다음날 사용할 정책 파라미터를 자동으로 조정하는 **일일 정책 보정 루프**를 통해 물리적 일관성 + 경험적 보정 + 제약 기반 안정성이 결합된 형태로 동작하도록 설계함



□ 모듈별 기능 및 역할

1) 데이터 전처리·표준화 모듈³⁾

- 센서 로그와 제어 로그를 시간축 기준으로 일치시키고, 파생변수·물리 모델에서 사용 가능한 형태로 정제
- 전원 장애, PLC 오류, 센서 점프값 등은 제외(마스킹)하여 물리 반응을 왜곡하지 않도록 처리
- 조도/일사 등 서로 다른 단위를 W/m² 기준으로 환산하여, DLI·일사 유효계수 계산에서 일관되게 사용
- 제어 신호를 정규화된 내부 표현으로 변환하여 후속 모듈에서 공통적으로 사용

2) Ver3.0은 제어전략 후보 생성, 비용 평가 구조를 내부 수식 기반 결정 정책 형태로 구체화하여, 격자형 후보 집합 코드를 내부에서 표현함

3) 2025년 12월 기준 내부 센서 이상치/결측치 보간을 위한 모듈은 탑재되어 있지 않음

할 수 있도록 함

2) 파생변수·상태벡터 생성 모듈

- 생리·결로 안전 변수, 광·에너지 균형 변수, 물리 안전·기구 한계 변수를 실제 로그에서 계산해 상태벡터(State vector)의 핵심 요소로 제공
- 열·수분 평형에 기반한 VPD, 이슬점(Tdew), 이슬점 여유(ΔT_{cond}), rh_90_min_1h, cond_risk_10m 등 생리·결로 관련 파생변수 계산
- 방사·에너지 수지에 기반한 DLI, 청천 누적 일사(cs_sum_jcm2), SunRatio, LightETA, vent_loss_proxy 등 광·에너지 변수 산출
- 내·외기 온도차(dT), ACH_min, RampLim, degnin_heat_cool 등 물리 안전 및 기구 한계 변수 계산
- 센서 로그를 입력으로 받아 파생변수 열(column)로 추가한 확장된 시계열 테이블을 반환하고, 이 테이블이 이후 모든 제어·평가 모듈의 기본 입력이 되도록 설계됨
- 상태벡터 $X(t)$ 는 다음을 포함하는 구조로 정리됨

$$X(t) = \{\text{센서값, 파생변수, 정책 파라미터, 물리 파라미터 요약}\}$$

3) 물리 파라미터 저장소·조회 모듈

- 단일 구획 모델 기반으로 온실별·기간별로 식별된 값이며, 제어 루프에서 단기 열·광 반응을 추정하는데 사용됨
- 파라미터는 기본값(x_{def})과 식별치(x_{est}) 가중합으로 결정하고 온실별 물리적 이질성 및 불확실성을 반영하는 데 사용함

$$x_{eff} = (1 - \lambda)x_{def} + \lambda x_{est}$$

- 환기 개도율을 $x \in [0, 1]$, 풍속을 w 라고 하면 환기율은 다음과 같은 준선형 모델로 표현됨

$$ACH(x, w) \simeq a_0 + a_1x + a_2w + a_3xw$$

- 목표 환기율을 만족하는 개도율은 다음과 같이 역산 가능

$$x = \frac{ACH_{target} - a_0 - a_2w}{a_1 + a_3w}$$

(1) 물리 파라미터 적용-열응답·환기·일사 반응 해석

- 제어 루프 실행 시에는 식별된 물리파라미터를 이용하여 단기 온도 응답을 근사 계산하고 이를 제약 생성과 정책 평가에 활용함. 시간 간격 Δt (시간 단위)에서 내부 온도 변화 ΔT_{in} 은 단일 구획 근사에 따라 다음과 같이 표현됨

$$\Delta T_{\epsilon}(t) \simeq \frac{1}{C} (Q_{heat}(t) + \eta I_t(t)A - UA[T_{\epsilon}(t) - T_{out}(t)] - K_{vent}f_{vent}(t)\max(T_{\epsilon}(t) - T_{out}(t), 0))\Delta t$$

- 여기서 $Q_{heat}(t), I_t(t), A, f_{vent}(t)$ s는 각각 히터 공급열량, 순간 일사량, 온실 외피 면적, 환기 개도율(0~1)으로 정의하고 제어기는 후보 정책 별로 예측되는 단기 온도 변화를 계산하고, ①과도한 환기에 따른 열손실, ②일사 증가에 따른 온도 상승 위험, ③난방 부족에 의한 목표 온도 미달 위험을 사전에 평가하는 데 사용함

(2) 작물·재배단계 기반 목표값 및 안전 제약의 수식화

- 작물 종류 c , 재배 단계 s , 시간대 h (주간/야간), 계절 q 에 따라 다음의 목표값 및 허용 여유 등을 테이블 기반으로 조회

- 온도 목표: $T_{target}(c, s, h, q)$
- VPD 목표: $VPD_{target}(c, s, h, q)$
- DLI 목표: $DLI_{target}(c, s, q)$
- 허용 여유폭: $\Delta T_{margin}, \Delta VPD_{margin}, \Delta DLI_{margin}$
- 결로 안전 여유 하한: $\Delta T_{cond, min}$ (예: 0.8°C)
- 과습/저 VPD 허용 누적시간: TH_{rh}, TH_{vpd}
- 난방 대비 환기 손실 허용 비율: α (예: $0.2 \sim 0.3$)

- 온도·VPD 목표 범위는 다음과 같은 제약 수식으로 표현 가능

$$\begin{aligned} T_{min}(t) &= T_{target}(c, s, h, q) - \Delta T \\ T_{max}(t) &= T_{target}(c, s, h, q) + \Delta T \\ VPD_{min}(t) &= VPD_{target}(c, s, h, q) - \Delta VPD \\ VPD_{max}(t) &= VPD_{target}(c, s, h, q) + \Delta VPD \\ &\text{s.t} \end{aligned}$$

$$\begin{aligned} T_{min}(t) &\leq T_{pred}(t + \Delta t) \leq T_{max}(t) \\ VPD_{min}(t) &\leq VPD(t) \leq VPD_{max}(t) \end{aligned}$$

- DLI 제약은 다음을 충족해야만 함

$$DLI(t_{day}) \geq DLI_{target}(c, s, q) - \Delta DLI$$

- 결로 안전 제약은 다음과 같이 표현 가능하고 아래 수식을 위반할 위험이 있는 제어 조합(예: 급격한 환기 증가)은 정책 탐색 공간에서 제외함

$$\begin{aligned} \Delta T_{cond}(t) &= (T_{\epsilon}(t) - T_{dew})t \\ \Delta T_{cond}(t) &\geq \Delta T_{cond, min} \end{aligned}$$

- 난방-환기 동시 사용 제약 수식은 환기에 의한 열손실 수식에 난방 중 제약 조건을 걸어 동시 사용이 비효율적일 경우 정책 후보에서 제거

$$\begin{aligned} Q_{loss, vent} &= K_{vent} f_{vent} \max(T_{\epsilon} - T_{out}, 0) \\ &\text{s.t} \end{aligned}$$

$$Q_{loss, vent} \leq \alpha Q_{heat}$$

4) 제어 목표·제약 생성 모듈

- 작물 종류, 재배 단계, 시간대(주간/야간), 계절 정보 등을 바탕으로 목표 온도, VPD 범위, DLI 목표, 결로·과습·환기 부족 등의 안전 제약을 수식 형태로 생성
- 물리 파라미터와 결합하여 허용 가능한 제어 조합의 영역을 동적으로 산출

5) 제어전략 후보 생성 모듈

- 현재 상태벡터와 목표·제약 정보를 입력으로 받아, 구동부(히터, 환기창, 커튼, 유동팬 등)에 대한 제어 후보 조합을 생성
- 강화학습 기반의 무작위 탐색이 아닌, 정의된 정책 템플릿/물·격자(Grid) 기반 후보 생성 로직 사용(예: 난방 출력 $\in[0, 30, 60, 100\%]$, 환기 개도율 $\in[0, 10, 30\%]$ 등 제한된 조합을 생성하되, 시간대·상태에 따라 후보 공간을 축소하여 계산 비용을 줄임)

6) 제약 기반 필터링·비용 평가 모듈

- 제어전략 후보 중, 파생변수·물리 파라미터에 기반한 안전 제약, 물리 제약을 위반하는 후보를 1차 필터링(결로·과습·VPD 제약 여부, 난방-환기 동시 사용 제약 위반 여부, 램프 제약 위반 여부, 예측 온도 변화가 목표 범위를 벗어나는지 여부)하고, 남은 후보에 대해 안정성(목표대역 체류율), 에너지 사용, 제약 위반 패널티를 반영한 비용함수로 점수를 계산

$$J = w_1 |T_{pred} - T_{target}| + w_2 E_{pred} + w_3 r$$

- 최소 비용을 갖는 후보가 최종 정책으로 선택됨

7) 최종 제어명령 산출·구동부(Actuator) 제어 모듈

- 선택된 제어전략 후보를 각 장비의 실제 제어 신호로 변환하여 PLC/제어기에 전달함
- 장비별 응답 특성(비선형성, dead-band, 최소 동작 시간)을 반영
- 램프 제약을 적용하여, 직전 제어 명령과 차이가 너무 클 경우 변화량을 제한

8) 로그 저장·일일 성능 평가·정책 보정 모듈

- 제어기에서 발생한 모든 상태·행동 결과를 로그로 축적하고, 일 단위로 성능을 평가하여 정책 및 물리 파라미터를 보정하는 역할을 수행
- 목표대역 체류율, 평균 편차(mdev), 제약 위반 빈도, 에너지 사용량, 난방·환기 동시 사용 시간 비율등을 계산
- 성능 평가에 따라 정책 파라미터(예: 목표 온도 보정, 후보 전략 가중치 조정, 제약의 보수성 정도)를 자동 조정하는 역할을 수행


- 물리 파라미터 식별 모듈과 연계하여, 성능 저하·반응성 변화가 감지될 경우 물리 파라미터 재식별을 트리거하도록 설계
- 현재는 배치 작업(스케줄러)로 구현되어, 실시간 제어 루프와 독립적으로 수행되도록 설계함

□ AI 자율제어기 내부 구조(Inner-Outer-Controller) 및 책임 분리 설계

1) 삼단 구조 설계 이유

- 스마트온실 환경 제어는 실시간 반응성(Real-time Responsiveness)과 장기적 안정성(Long-horizon Stability)이 요구되는 다계층 시스템으로 ①실시간 제어는 현재 센서 상태, 파생변수, 식별된 물리 파라미터, 정책 파라미터를 종합해 즉각적인 제어명령을 내려야함. ② 일일 장기 정책 보정은 목표대역 체류율, 평균편차등 운영 성능을 분석하여 정책 파라미터를 업데이트해야함. ③여기서 물리 파라미터는 온실 구조·장비의 이종성, 계절·기상 변화, 장비 노후화 등으로 인해 지속적으로 드리프트가 발생할 수 있으므로 파라미터 관리 계층 또한 독립된 구조로 운영되어야함
- 실시간 제어(Inner)와 정책 학습·보정(Outer)의 역할을 분리해 안정성 확보
- 물리 파라미터 적용을 제어 루프에 자연스럽게 삽입하기 위해 물리 파라미터 계산 후 매 사이클마다 재계산할 필요가 없으므로 컨트롤러에서 일괄 로딩하고 실시간제어(Inner)에서 활용
- 온실별 파라미터 변경(Inner: 제어 엔진), 정책 튜닝(Outer: 성능 기반 정책 조정 엔진), 제어 로직 수정(Controller: 오케스트레이터), 각각의 책임 분리가 명확해 디버깅·보정·확장성에서 유리
- 강화학습 기반 제어의 불안정성을 배제하고, 점진적 개선형 정책 보정이 가능한 구조로 설계

2) AI 자율제어기 계층 구조 개요



3) 실시간 제어 실행기(Inner Layer) 상세 설계

(1) 설계 철학 및 계층적 구조

- 실시간 제어 실행기(Inner, 이하 Inner)는 AI 자율제어 시스템에서 결정적·물리 기반·저지연 제어를 보장하는 핵심 계층으로 다음과 같은 세 원칙을 준수하도록 설계됨

- **물리 기반 제어(Physics-informed Control)**: 스마트온실의 온도·수분·광 반응은 순수 ML 예측으로 대체할 수 없으며 제어 명령, 물리 반응, 센서 변화의 인과 구조가 열역학·수분평형·방사수지에 의해 지배됨. 따라서 Inner는 RL·ML 탐색 방식을 배제하고 실제 물리식 기반 결정적 제어 공식을 제어 루프에 직접 적용함(단일 구획 동역학 모형 및 수치 적분 수식)
- **결정적·저지연 구조(Deterministic Low-Latency Control)**를 사용해 강화학습 기반의 탐색에서 생길수 있는 문제인 제어 신뢰성과 지연 문제를 극복. Inner는 수식 기반 즉시 계산 방식을 통해 모든 제어값(난방, 환기 커튼)을 계산함

$$u(t) = f_{\theta}(X(t), P_{policy}, P_{physics})$$

- 위 수식에서 $X(t)$ 는 파생변수 포함 상태벡터, P_{policy} 는 정책 파라미터, $P_{physics}$ 는 식별된 물리 파라미터로 Inner의 목적은 빠르고 안전하게 결정된 제어값을 PLC에 전달하는 것
- **제약 기반 안정성 구조(Constraint-first Execution)**는 제어 계산 과정에서 즉시 다음 제약식을 적용해 물리적으로 위험한 조합을 아예 생성하지 않도록 함

$$\Delta T_{cond}(t) = T_{\epsilon}(t) - T_{dew}(t)$$

$$\Delta T_{cont}(t) \geq \Delta T_{cond, min}$$

- 조건을 만족하지 않는 조합은 Inner 단계에서 즉시 제거

(2) 실시간 입력 구조와 상태 해석

- Inner 는 센서 원시 값을 직접 사용하지 않으며 파생변수 모듈에서 계산된 생리·열·광·수분 기반 상태를 사용

- 센서 기반 실시간 상태 $S_{raw}(t)$

$$S_{raw}(t) = \{T_{\epsilon} RH, Co2, I, T_{out}, W\}$$

- 파생변수 기반 생리·안전 상태 $S_{bio}(t)$

$$VPD(t) = \frac{610.78 e^{\frac{17.277}{T+237.3} - RH e_s(T)}}{1000}$$

$$\Delta T_{cond}(t) = T_{\epsilon}(t) - T_{dew}(t)$$

$$rh90min1h(t) = \sum_{i=t-60}^J 1_{RH_i \geq 90}$$

- 광·에너지 상태 $S_{rad}(t)$

$$DLI(t) = \sum_{\text{알}}^{\text{알}} PAR_i \Delta t_i$$

- 청천 일사는 Haurwitz Clear Sky Model로 계산하고 LightETA, SunRatio 생성

$$I_{cs} = 1098 \cos^3(Z) e^{-0.057/\cos(Z)}$$

- 센서 기반 실시간 상태, 파생변수 기반 생리·안전 상태, 광·에너지 상태, 물리 파라미터 요약의 4가지 상태집합을 입력값으로 받음

- 물리 파라미터 요약 $P_{physics}$

$$P_{physics} = \{UA, C, \eta_{rad}, a_{vent}, b_{vent}\}$$

(3) 정책 파라미터 기반 동적 목표 생성

- 정책 파라미터는 단순한 룰셋이 아니라 시간대·생장단계⁴⁾·환경 편향을 반영해 목표 상태를 동적으로 조정하는 역할을 함

- 목표 온도 생성식과 정책 편향(Bias) 적용 수식은 각각 다음과 같음

$$T_{\square}(t) = f_{crop}(c, s, h, q)$$

$$T_{target}(t) = T_{\square}(t) + B_T$$

- 정책 편향 수식은 야간 과냉 방지, 주간 과열 보정 등 운영 경험을 반영한 구조

(4) 제약 주권 수식 정리

- 모든 제어는 아래 제약식을 동시에 만족해야 함

- 온도 제약

4) 생장단계는 메인 함수에서 딸기의 5가지 생장단계 영양생장기, 휴면기, 꽃눈 분화 및 개화기, 열매 비대 및 수확기, 런너 형성기의 5개 단계(Stage 1~5)로 메인함수에서 지정할 수 있음

$$\begin{aligned}
T_{\min}(t) &= T_{\text{target}}(t) - \Delta T_{\text{margin}} \\
T_{\max}(t) &= T_{\text{target}}(t) + \Delta T_{\text{margin}} \\
s.t \quad T_{\epsilon, \text{pred}}(t + \Delta t) &\in [T_{\min}(t), T_{\max}(t)]
\end{aligned}$$

- VPD 제약

$$\begin{aligned}
VPD_{\min}(t) &= VPD_{\text{target}}(c, s, h, q) - \Delta VPD \\
VPD_{\max}(t) &= VPD_{\text{target}}(c, s, h, q) + \Delta VPD \\
s.t \quad VPD &\in [VPD_{\min}, VPD_{\max}]
\end{aligned}$$

- 결로·과습 안전 제약

$$\begin{aligned}
\Delta T_{\text{cond}}(t) &= T_{\epsilon}(t) - T_{\text{out}}(t) \\
s.t \quad \Delta T_{\text{cond}}(t) &\geq T_{\text{cond}, \min}
\end{aligned}$$

- DLI 제약

$$DLI(t) \geq DLI_{\text{target}}(c, s, q) - \Delta DLI$$

- 난방-환기 동시 사용 제약

$$\begin{aligned}
Q_{\text{loss}, \text{vent}}(t) &= K_{\text{vent}} f_{\text{vent}}(x)(T_{\epsilon} - T_{\text{out}}) \\
s.t \quad Q_{\text{loss}, \text{vent}}(t) &\leq \alpha Q_{\text{heat}}(t)
\end{aligned}$$

(5) 제어 가능영역(Feasible Action Space) 실시간 계산 원리

- Inner layer는 아래 단계를 통해 제약을 만족하는 제어 가능 영역 $A(t)$ 를 실시간으로 산출

- (1단계- 제어 입력 후보 생성) 격자 기반 생성⁵⁾
- (2단계 - 물리식으로 각 후보의 효과 예측) 각 후보 a_i 에 대해 내부 온도 예측

$$T_{\epsilon, \text{pred}}(t + \Delta t | a_i)$$

- (3단계 - 모든 제약을 만족하는 후보만 선별) 제어 가능 영역 $A(t)$ 에 저장
- (4단계 - 비용함수로 최종 선택) 비용 함수에서 후보 a_i 최저값을 만족하는 후보를 선택

$$\begin{aligned}
J(a_i) &= w_T |T_{\epsilon, \text{pred}} - T_{\text{target}}| + w_E E(a_i) + w_C C_{\text{risk}}(a_i) \\
a^* &= \arg \min_{a \in A(t)} J(a)
\end{aligned}$$

4) 일일 정책 보정기(Outer Layer) 상세 설계

(1) 설계 목적과 위치

- 일일 정책 보정기(Outer)는 Inner이 사용하는 정책 파라미터(Policy State)를 하루 단위 성능 지표를 기반으로 자동 조정하는 계층

5) 현 구현(Ver3.0)에서는 환기, 난방, 커튼 제어에 대해 페루프 수식 + 제약 기반 직접 계산 방식을 사용하여, 향후 고차원 제어 전략 확장을 위해 격자 기반 후보 생성, 비용함수 구조로써 확장 필요

- Inner는 현재 시점에서 가장 합리적인 제어값을 결정하는 반면, Outer는 하루 동안의 결과를 평가하여, 내일의 제어 성격을 더 좋게 바꾸는 역할을 수행함

$$(u_{heat}, u_{vent}, u_{curtain}, \dots) = f_{\epsilon \neq r}(X(t), P_{policy}, P_{physics})$$

- 따라서 Outer는 배치(Batch)형/저빈도(일 1회), Inner는 스트리밍/고빈도로 동작하도록 설계됨

(2) 입력 데이터와 일일 성능 지표 정의

- Outer의 입력은 일자별 로그 시계열, 일출/일몰 시각, 일자별 목표 온도 설정값, 기존 정책 상태를 입력으로 온도 목표대역 커버리지 및 평균 편차를 계산함
- Outer에서는 주간 온도 목표대역 체류율, 야간 온도 목표대역 체류율, 주간 평균 편차, 야간 평균 편차를 다음과 같이 계산함
- 각 시점 t 에 대해, 목표대역 $[T_{target} - \Delta, T_{target} + \Delta]$ 안에 있는지 여부를 표시하는 지시함수를 산출

$$I_{\epsilon} = \begin{cases} 1, & \text{if } |T_{\epsilon} - T_{target}| \leq \Delta \\ 0, & \text{otherwise} \end{cases}$$

- 주간/야간 커버리지 계산

$$cov_{day} = \frac{\sum_{t \in day} I_{\epsilon}(t) \Delta t}{\sum_{t \in day} \Delta t}, cov_{night} = \frac{\sum_{t \in night} I_{\epsilon}(t) \Delta t}{\sum_{t \in night} \Delta t},$$

- 주간/야간 평균 편차 계산

$$mdev_{day} = \frac{\sum_{t \in day} (T_{\epsilon}(t) - T_{day}) \Delta t}{\sum_{t \in day} \Delta t}, mdev_{night} = \frac{\sum_{t \in night} (T_{\epsilon}(t) - T_{night}) \Delta t}{\sum_{t \in night} \Delta t}$$

- 주/야간 구분은 일출·일몰 시각을 기준으로 타임스탬프를 Asia/Seoul로 정규화한 시각과 위·경도를 입력값으로 한 시각을 이용해 계산됨

(3) 일일 성능 점수 함수와 수용 기준

- Outer는 네 개의 성능지표(KPI)를 하나의 스칼라 점수로 계산함. 내부 함수는 다음과 같이 정의함

$$cov = 0.5cov_{day} + 0.5cov_{night}$$

$$dev = 0.5|mdev_{day}| + 0.5|mdev_{night}|$$

- 일일 성능 점수

$$score = cov - \beta dev$$

- 정책 업데이트의 수용 기준은 다음과 같은 제약으로 표현됨. 이전 점수

$score_{prev}$, 새 점수 $score_{\neq w}$ 에 대해

$$score_{\neq w} \geq score_{prev} - \epsilon$$

- 수치 노이즈나 미세한 차이로 인한 불필요한 롤백을 방지하기 위해 ϵ 는 1e-4로 설정
- 위 제약을 만족하지 못할 경우, Outer는 정책 업데이트를 거부하고 이전 상태를 유지함

(4) 정책 파라미터 자동 보정 규칙

- Outer는 KPI와 점수에 따라 ①온도 편향, ②데드밴드/비례 밴드, ③환기 민감도, ④ 커튼 민감도 정책 파라미터를 자동 조정함

- 온도 편향 보정은 냉방 모드⁶⁾와 난방 모드에 따라 목표 온도 편향을 다르게 조정함
- 냉방 모드일 경우

$$\begin{aligned}\Delta T_{day} &= clip(-ndev_{day}, -\Delta T_{max}, 0) \\ \Delta T_{\exists ght} &= clip(-mdev_{\exists ght}, -\Delta T_{max}, 0)\end{aligned}$$

- 난방 모드일 경우

$$\begin{aligned}\Delta T_{day} &= clip(-ndev_{day}, 0, \Delta T_{max}) \\ \Delta T_{\exists ght} &= clip(-mdev_{\exists ght}, 0, \Delta T_{max})\end{aligned}$$

- 편향 업데이트

$$\begin{aligned}T_{daybias, \neq w} &= clip(T_{daybias, old} + \Delta T_{day}, -T_{\cap}, T_{\cap}) \\ T_{\exists ghtbias, \neq w} &= clip(T_{\exists ghtbias, old} + \Delta T_{\exists ght}, -T_{\cap}, T_{\cap})\end{aligned}$$

- 여기서 ΔT_{max} , $T_{\cap}$ 은 상수로, 하루에 너무 큰 목표 온도 변화를 허용하지 않기 위해 제한을 위한 수치
- 데드밴드 및 비례 밴드 조정은 목표대역 체류율이 낮을 때, 민감도를 높이고, 편차가 클 때는 제어 강도를 높이는 방식으로 조정

$$\begin{aligned}DB_{\neq w} &\begin{cases} clip(DB_{old} + \Delta DB, DB_{min}, DB_{max}) & \text{if } cov < cov_{target}, |mdev| < \delta_1 \\ DB_{old} & \text{otherwise} \end{cases} \\ PB_{\neq w} &\begin{cases} clip(PB_{old} + \Delta PB, PB_{min}, PB_{max}) & \text{if } cov < cov_{target}, |mdev| < \delta_2 \\ PB_{old} & \text{otherwise} \end{cases}\end{aligned}$$

- 환기 민감도는 주간/야간 평균 편차에 따라 환기 개방 정도를 자동 튜닝함

$$K_{window, day, \neq w} = clip(K_{window, day, old} + clip(k \cdot mdev_{day}, -\Delta K_{max}, \Delta K_{max}), K_{min}, K_{max})$$

- 온도가 항상 높게 유지되는 경향이면, 환기 민감도를 올려 더 적극적으로 환기

6) 경상북도 스마트팜 혁신밸리에서는 외부 온도에 따라 중앙 펌프를 이용해 온수와 냉수를 순환시키는 방식으로 구동기가 난방 모드 또는 냉방 모드 중 하나로만 작동하도록 되어 있으며, Ver3.0도 같은 방식을 사용함. 그러나 향후 난방과 냉방 구동기가 독립적으로 운영되는 환경에서는 이러한 운용 조건을 반영하여 시스템 업그레이드를 할 필요성이 있음

를 열게 하고, 항상 낮게 유지되면, 민감도를 낮춰 과도한 환기를 줄이는 구조

- 커튼 민감도는 일사 부족/과잉과 온도 편차를 함께 고려해 차광 커튼 반응 정도를 조정

$$a_{curtain, \neq w} = \begin{cases} clip(a_{curtain, old} + \Delta a, a_{min}, a_{max}), & \text{if } mdev_{day} \geq \theta_1, \sum Ratio > r_1 \\ clip(a_{curtain, old} - \Delta a, a_{min}, a_{max}), & \text{if } mdev_{day} > -\theta_2, \sum Ratio < r_2 \\ a_{curtain, old} & \text{otherwise} \end{cases}$$

5) 통합 오케스트레이터(Controller) 구조 및 동작

(1) 계층 내 위치와 역할

- Controller는 Inner, Outer, 물리 파라미터 식별기, 파생변수 엔진을 하나의 일관된 제어 API로 묶는 상위 오케스트레이터임
- 외부 시스템(상위 운영 플랫폼, 관제 대시보드 등)은 Controller만 호출하여, ① 현재 시점 장비 제어 명령, ②최신 정책 상태 및 일일 성능 요약, ③물리 파라미터 사용 현황 요약에 대한 정보를 가져올 수 있음

(2) 물리 파라미터 컨텍스트 생성 및 보정(Calibration)

- Controller는 단일 구획 식별 모듈이 산출한 파라미터 세트

$$\theta_{est} = \{C, UA, k_{heat}, \eta, k_{vent}, \dots\}$$

- 시스템 기본값(설계 기반 prior) $\theta_{default}$ 및 보정 계수 $\lambda \in [0, 1]$ 를 받아 다음 식과 같이 물리 파라미터 컨텍스트를 구성함

$$\theta_{used} = (1 - \lambda)\theta_{default} + \lambda\theta_{est}$$

- 보정 계수는 식별 신뢰도·데이터 양·센서 품질에 따라 조정되며, 초기에는 보정 계수를 낮게, 데이터가 충분하고 식별 안정성이 확보되면 보정 계수를 점진적으로 높여 농가/온실별 특성을 더 많이 반영하는 형태로 구현함

(3) 실시간 제어 루프에서의 동작

- Controller의 실시간 루프는 ①센서 입력 + 제어 로그 수집, ② 파생변수 및 안전 상태 계산, ③물리 파라미터 컨텍스트 로딩, ④Inner 호출, ⑤구동부 명령 전송의 과정으로 10분마다 반복됨

- 센서 입력 및 제어 로그 수집

$$X_{raw}(t) = \{T_e, RH, I_t, T_{out}, \dots\}$$

- 파생변수 및 안전 상태 계산: 파생변수 엔진으로부터 VPD, ΔT_{cond} , DLI, SunRatio, ACH_min, RumpLim 등을 계산하고 안전캡과 제약에 필요한 값을 생성
- 물리 파라미터 컨텍스트 로딩: 현재 온실 ID, 시점에 맞는 θ_{used} 조회

- Inner 호출. 여기서 $X(t)$ 는 센서값 + 과생변수 + 안전상태 + 정책/물리 요약
을 포함하는 상태벡터

$$u(t) = f_{\epsilon \neq r}(X(t), P_{policy}, \theta_{used})$$

- 구동부 명령 전송: $u(t)$ 를 PLC 신호 규격에 맞게 변환(create_io.py)하여 구동
부에 전달

(4) 일일 배치 루프에서의 동작

- Controller는 별도의 배치 프로세스로 Outer와 물리 식별 모듈을 조율함. 동작
과정은 ①일일 로그 집계 및 KPI계산, ②Outer 실행 및 정책 상태 갱신, ③물리
파라미터 드리프트 감지 및 재식별 트리거, ④갱신된 물리 파라미터 배포의 과정
으로 동작함

(5) Controller 출력 구조

- 외부에서 Controller를 호출하면 ①실시간 제어 출력(control_actuation⁷⁾), ②정
책 상태 및 성능 요약(control_log), ③물리 파라미터 상태 요약(control_params)
의 세 가지 정보 각각의 데이터베이스에 10분 단위로 적재 및 반환

3.6. AI 자율제어기 견고성 검증 방법론

1) AI 자율제어기 견고성 검증 목적

- AI 자율제어기는 제어 명령 단위의 정오 판단이 아닌, 제어 시퀀스가 만들어내는
환경 궤적의 안정성을 평가 대상으로 함
- 그러므로, 검증 대상은 환경 반응 모델 + 제어 정책이 결합된 페루프 시스템의
견고성을 검증하는 것을 목표로 함
- 데이터의 가용성에 따라 검증 가능 범위가 달라지므로, ①데이터가 없는 경우,
②데이터가 있는 경우로 평가 체계를 분리하여 작성함

2) 검증 시나리오 분류: 데이터 가용성 기반 평가 모드 정의

- 무데이터 환경 검증
 - 내부 환경 로그 및 충분한 제어 이력 데이터가 존재하지 않는 초기 도입 환경
 - 물리 파라미터 식별이 불가능하거나 신뢰도가 낮은 상태
- 제한적 데이터 환경 검증
 - 단기 로그(수일~수주) 또는 일부 이벤트 구간만 존재
 - 물리 파라미터의 부분 식별(Partial identification)만 가능한 상태
- 충분한 데이터 기반 검증
 - 최소 1개월 이상 누적 로그 확보

7) farmstom.control_actuation, farmstom.control_log, farmstom.control_params

- 물리 파라미터가 안정적으로 식별·검증된 상태

3) 무데이터 환경에서의 견고성 검증 방법론

(1) 검증 문제 정의: 페루프 시스템의 안정성/견고성 평가

- 무데이터 환경에서 검증 대상 또한 제어명령 $a(t)$ 의 단발 정오가 아닌, 제어 시퀀스가 만드는 내부 상태 궤적 $x(t)$ 의 안정성을 검증함
- 따라서 검증은 다음 페루프 합성계에 대해 진행함

$$a_t = \pi_\phi(x_t, u_t; p_{policy})$$

$$x_{t+1} = f_\theta(x_t, u_t, a_t), t = 0, 1, \dots, T-1$$

- x_t : 내부 상태(온·습도 등), u_t : 외부 경계조건(외기, 일사, 풍속 등), a_t : 제어 입력(난방·환기 등), θ : 물리 파라미터(불확실), ϕ : 정책(결정 규칙/비용함수)로 정의할 경우
- 무데이터 환경에서는 물리 파라미터를 식별하지 못하므로, $\theta \sim p(\theta)$ 로 두고 **불확실성 하에서 제약 위반 위험이 낮은지를 평가**하는 것이 목적

(2) 상태·경계조건·파생변수 정의

- 무데이터 환경에서 최소 상태는 다음으로 정의함. 상태벡터 x_t , 외부 경계조건 u_t , 파생변수(검증 지표 계산용; 포화수증기압, 내부 상태습도, VPD, 이슬점, 결로 여유 등)

$$x_t = \{T_{\epsilon t}, e_{\epsilon t}, CO2_{\epsilon t}\}$$

$$u_t = \{T_{out,t}, RH_{out,t}, I_t, w_t, CO2_{out,t}\}$$

(3) 내부 환경 반응 모델

- 환기율(ACH) 모델(개도율을 환기율로 변환) 제어 입력으로 환기 개도율이 들어오면 환기율(ACH)은 준선형/포화 모델로 정의

$$ACH_t = clip(a_0 + a_1 x_t + a_2 w_t x_t, 0, ACH_{max})$$

- 열 동역학(오일러 이산화): 연속시간 에너지 평형 방정식은 다음과 같이 정의 (cur은 차광커튼)

$$C \frac{dT_{ln}}{dt} = UA(T_{out} - T_{ln}) + \eta AI_t(1 - cur_t) + k_{heat} u_{heat,t} + \rho c_p V \frac{ACH_t}{3600} (T_{out} - T_{ln})$$

$$T_{ln,t+1} = T_{ln,t} + \frac{\Delta t}{C} \left[UA(T_{out,t} - T_{ln,t}) + \eta AI_t(1 - cur_t) + k_{heat} u_{heat,t} + \rho c_p V \frac{ACH_t}{3600} (T_{out,t} - T_{ln,t}) \right]$$

- 수분 동역학(수증기분압 상태)

$$e_{ln,t} = e_{ln,t} + \Delta t \left[\frac{ACH_t}{3600} (e_{out,t} - e_{ln,t}) + S_{evap}(t) \right]$$

$$e_{out,t} = RH_{out,t} e_s(T_{out,t})$$

- 증발/증산 소스는 무데이터에서 계산의 복잡성을 낮추기 위해 물리적 방향성만 반영하는 단순식으로 정의

$$S_{evap}(t) = k_{evap} I_t \max(0, T_{ln,t} - T_0), \quad I_t \text{는 최대 일사에서 정규화한 수치}$$

- 이산화탄소 동역학(환기 교환 + 공급 - 광합성 흡수)

$$CO2_{ln,t+1} = CO2_{ln,t} + \Delta t \left[\frac{ACH_t}{3600} (CO2_{out,t} - CO2_{ln,t}) + S_{lnj} u_{co2,t} - U_{photo}(t) \right]$$

$$U_{photo}(t) = k_{photo} I_t g_T(T_{ln,t}) g_v(VPD_t)$$

$$g_T = clip((T-5)/20, 0, 1), g_v = clip(VPD/1.2, 0, 1)$$

(4) 제어 정책 내부 구조(①후보 생성, ②제약 필터링, ③비용 최소화)

- 무데이터 모드에서도 정책을 설명 가능한 최적화 형태로 정의하면, 제어값이 입력될 때 과정을 수식으로 정의 가능

- 후보 행동 집합을 격자 기반으로 정의

$$A = \{u_{heat}\} \times \{x\} \times \{curtain\} \times \{u_{co2}\}$$

- 실행가능 제어영역을 각 후보 $a \in A$ 에 대해 단기 예측 제약 위반 검증

$$\widehat{x}_{t+1}(a) = f_\theta(x_t, u_t, a)$$

s.t

$$T_{\min} \leq \widehat{T}_{ln,t+1}(a) \leq T_{\max}$$

$$\Delta \widehat{T}_{cond,t+1}(a) \leq \delta_{\min}$$

$$|x(a) - x_{t-1}| \leq r_{\max}$$

$$Q_{ventloss}(a) \leq a Q_{heat}(a)$$

- 위 조건을 만족하는 후보 산출

$$A_t^* = \{a \in A | g_i(\widehat{x}_{t+1}(a)) \leq 0, \forall_i\}$$

(5) 비용함수 최소화

- 제어 정책에서 필터된 후보 중 비용이 최소인 제어를 선택

$$a_t = \underset{a \in A^*}{\operatorname{ARGMIN}} J(a; x_t, u_t)$$

- 비용함수 정의는 다음과 같음

$$J(a) = w_T (\widehat{T}_{ln,t+1}(a) - T^{ref})^2 + w_{VPD} \text{hinge}(VPD^{\min} - \widehat{VPD}_{t+1}(a)) + w_E (Q_{heat}(a) + \lambda_v Q_{ventloss}(a)) + w_x |x(a) - x_{t-1}| + w_s \sum_i^K \text{hinge}(g_i(\widehat{x}_{t+1}(a)))$$

- 여기서 $\text{hinge}(z) = \max(0, z)$, T^{ref} 는 작물의 생육단계별 최적 온도

(6) 제어값 입력 기반 검증

- 무데이터 모드에서 외부로부터 제어값 a_t 가 주어지는 오픈루프 입력이거나, 정책이 산출하는 폐루프 출력, 두 경우 모두, 실제 환경 반응 모델 f_θ 이 적용되기 전에 입력 검증과 투영 절차를 수행하여 물리적으로 불가능하거나 위험한 제어 명령을 차단함

$$x_{t+1} = f_\theta(x_t, u_t, a_t^{valid}), \quad a_t^{valid} = \prod^c(a_t)$$

- 유효성 검사는 ①박스제약: 제어 입력은 장비 구동 제약 및 표현 범위를 반드시 만족해야함
- ②램프 제약: 구동부 및 안정성 측면 단위 시간 내 변화량 제한을 거침
- 입력 a_t 가 유효하지 않거나(박스/램프 위반), 사전 정의된 안전 규칙(예: 난방-환기 동시 사용 금지)을 위반하는 경우, 다음의 투영 문제로 안전 제어 a_t^{proj} 계산

$$a_t^{proj} = \arg \min_{a \in C} \|a - a_t\|^2$$

(7) 견고성 평가 지표

- 무데이터 모드에서 견고성은 단일 시나리오에서의 평균 성능이 아닌, 불확실성 하에서 안전 제약 위반이 얼마나 억제되는지를 평가해야함. 이를 위해 각 시물레이션 롤아웃에서 안전 성능지표(KPI)를 계산하고, 이를 최악 분위수 또는 CVaR로 집계함
- 지표는 온도 제약 위반률, 결로 위험 위반률, 과습/저 VPD 위반률, 최대 연속 위반 길이, 난방-환기 동시 사용 비효율(열손실 기반), 제어 안정성의 6가지 지표로 평가함

성능 지표 정의	수식
온도 제약 위반률	$m_T = \frac{1}{T} \sum_{t=1}^T 1[T_{\ln,t} < T_{\min} \vee T_{\ln,t} > T_{\max}]$
결로 위험 위반률	$m_{cond} = \frac{1}{T} \sum_{t=1}^T 1[\Delta T_{cond,t} < \delta_{\min}]$
과습/저VPD 위반률	$m_{RH} = \frac{1}{T} \sum_{t=1}^T 1[RH_{\ln,t} > RH_{\max}], m_{VPD} = \frac{1}{T} \sum_{t=1}^T 1[VPD_t <$
최대 연속 위반 길이	$m_T^{run} = \max \leq n(1[tempviolation])$
난방-환기 동시 사용 비효율	$Q_{ventloss,t} = \rho c_p V \frac{ACH_t}{3600} \max(0, T_{\ln,t} - T_{out,t})$ $m_{hw} = \frac{1}{ H } \sum_{t \in H} 1[Q_{ventloss,t} > a Q_{heat,t}], H = \{t : u_{heat} = 1\}$

제어 안정성	$m_{lr} = \sum_{t=2}^T x_t - x_{t-1} , m_{sw} = \sum_{t=2}^T 1[u_{heat,t} \neq u_{heat,t-1}]$
--------	--

- 무데이터 모드에서는 물리 파라미터가 식별되지 않으므로, $\theta \sim p(\theta)$ 로 두고, 외부 경계조건 시나리오(날씨/일사)도 $w \sim p(w)$ 로 가정함. 각 반복에서 KPI를 계산하면

$$M^{(i)} = M(\theta^{(i)}, w^{(i)}), \theta^{(i)} \sim p(\theta), w^{(i)} \sim p(w)$$

- 최악분위(VaR), 최악 10% 평균(CVaR)는 각각 $Q_{0.9}$, $CVaR_{0.9}$ 로 표기하며 수식은 다음과 같음

$$Q_{0.9}(M) = \inf\{m : P(M \leq m) > 0.9\}$$

$$CVaR_{0.9}(M) = E[M | M \geq Q_{0.9}(M)]$$

- 추정된 시나리오 샘플링을 통한 몬테카를로 시뮬레이션을 적용하여 경험적으로 추정함

- 시나리오 샘플링

$$\theta^{(i)} \sim p(\theta), w^{(i)} = u_{0:T}^{(i)} \sim p(w)$$

- 페루프 돌아옴
- KPI 계산 및 저장
- 분위수/CVaR의 경험적 추정

$$\hat{Q}_{0.9}(M) = Q_{antile_{0.9}}(\{M^{(i)}\})$$

$$\widehat{CVaR}_{0.9}(M) = \frac{1}{I_{0.9}} \sum_{i \in I_{0.9}}^K M^{(i)}, I_{0.9} = \{i : M^{(i)} \geq \hat{Q}_{0.9}(M)\}$$

- 통과 기준은 평균이 아닌 꼬리 위험을 기준으로 다음과 같이 정의

$$\hat{Q}_{0.9}(m_T) \leq \tau_T \hat{Q}_{0.9}(m_{cond}) \leq \tau_{cond} \hat{Q}_{0.9}(m_T^{run}) \leq L_T$$

$$\widehat{CVaR}_{0.9}(m_T) \leq \bar{\tau}_T, \widehat{CVaR}_{0.9}(m_{cond}) \leq \bar{\tau}_{cond}$$

(8) 무데이터 환경 검증의 한계와 역할 규정

- 무데이터 환경 견고성 검증은, 실측 내부 환경 로그와 물리 파라미터 식별 결과가 존재하지 않는 스마트 온실 초기 도입 단계에서 AI 자율제어기의 **안정성을 사전에 평가**하기 위한 최소 요건 검증 절차
- 본 검증은 물리 수식 기반으로 생성된 환경 데이터와 불확실성 분포 하에서, 제어 정책 또는 외부에서 주어진 제어 입력이 핵심 안전 제약을 반복적으로 위반하지 않음을 정량적으로 확인함
- 특히 평균 성능이 아닌, 최악 분위수 및 CVaR 기준의 지표를 사용함으로써 불리한 조건에서도 제어기가 물리적으로 위험한 상태로 진입할 확률을 정량적으로 산출하는 것이 가능함. 이는 본 검증이 성능 검증이 아닌 **안정성 하한(lower bound)** 검증임을 의미함

- 무데이터 환경 검증은 실제 온실에서의 절대적인 온도·VPD 제어 성능, 에너지 소비의 최적성 또는 비용 최소화 효과, 시설별 구조적 특성, 장비 노후화, 누설 등 현실 요소의 정확한 재현이 불가능하다는 한계점을 가지고 있음. 이는 환경 반응 모델이 실측 기반 식별 모델이 아닌 보수적 사전 분포에 기반한 물리 모델이기 때문이며, 데이터 축적 이후 단계에서 보완이 가능함

(9) 무데이터 환경에서의 견고성 검증(구현 모듈 사용) 예시⁸⁾

- 실측 데이터가 전혀 존재하지 않는 초기 도입 환경에서, 구현한 AI자율제어기가 물리적으로 위험한 제어를 하지 않는지를 사전에 검증 모듈
- 환경 데이터는 물리 수식, 확률 잡음, 일주기 구조를 생성된 시계열을 사용하여 제어기가 노출될 수 있는 합리적인 범위의 물리적 상황을 여러 시나리오 기반으로 생성
- 물리 파라미터의 경우, 단일 값이 아닌 사전 분포에서 무작위 샘플링을 통해 일반적인 온실 계열을 대표하는 가상 집합을 모의

시뮬레이션	온도 제약 위반률	온도 연속 위반 최대 길이	결로 위험 위반률	결로 위험 연속 위반 길이	과습 위반률	저VPD 위반률
1	0.601	91	0	0	0.0069	0.341
2	0.359	62	0.003	3	0.006	0.011
3	0.586	90	0.002	2	0.0079	0.296
4	0.496	78	0	0	0.004	0.191
5	0.427	69	0	0	0	0.013
6	0.510	79	0	0	0	0.029

- 온도 제약 위반률은 일부 시나리오에서 50% 이상으로 나타났으며, 온도 연속 위반 최대 길이 또한, 수십번 이상 지속되는 구간이 관측됨
- 위 시나리오에는 외기 온도가 장시간 불리한 가상 시나리오, 열손실이 큰 가상의 온실 구조, 난방 용량이 제한된 물리 파라미터 조합을 의도적으로 포함하며 이러한 조건에서 제어기는 무리한 난방이나 급격한 환기를 시도하지 않고 안전 제약을 유지하면서 보수적으로 온도 목표를 유지하는 전략을 시도하는 것을 확인할 수 있음
- 가상의 환경과 가상의 온실 특성 하에서도 제어기가 결로 및 과습을 유발하는 제어 조합을 구조적으로 회피함

8) 3.5.3. AI 자율제어기 견고성 검증 방법론-무데이터 환경에서의 견고성 검증 방법론

- 과습, 저VPD 위반율은 시나리오에 따라 크게 변동한 모습을 보여줌. 이는 무데이터 단계에서 의도적으로 설정한 온도 보존 우선, 결로 회피 우선의 결과로써 해석 가능함

4) 제한적 데이터 환경에서의 부분 검증 방법론

(1) 검증 문제 정의

- 제한적 데이터 환경이란, 내부 환경 로그 및 제어 로그가 수일에서 1개월 수준으로 제한되어 있어 계절·극한 기상·희귀 이벤트(한파, 장기 저일사, 강풍/강우로 인한 환기 제한)를 충분히 포함하지 못하는 상태를 의미함
- 이 경우, 실측 로그만으로는 제어 입력의 순수 효과를 관측할수 없음
 - 내부 온도 변화는 외부 기상, 일사, 풍속, 관성, 노이즈가 혼합된 결과이며, 단순 내부 온도 변화와의 비교는 인과적 근거가 부족함
- 본 환경에서의 AI 자율제어기 검증을 위해, 제어-환경 반응의 반사실(Counterfactual) 평가 또한 ①물리 기반 환경 반응 모델을 사용하며, ②실측 데이터는 물리 모델의 파라미터 불확실성을 사후확률(Posterior)로 축소하여 시뮬레이션 기반 평가의 신뢰성을 확보하는 방법을 사용함. ③최종 견고성 평가는 사후확률 기반 최악 위험(CVaR)로 정의하여, 제한적 실측에서도 현실 정합성과 최악 위험을 동시에 입증함

(2) 이벤트 기반 부분 식별과 검증 결합

- 상태-파라미터 동시 추정 문제 정의는 다음과 같음
 - 관측 데이터(실측)

$$y_{1:T} = \{y_t\}_{t=1}^T, y_t = (T_{ln,t}^{obs}, RH_{\epsilon,t}^{obs}, Co2_{ln,t}^{obs}, \dots)$$

- 입력 로그(외기 및 제어)

$$u_{1:T} = \{u_t\}, u_t = (T_{out,t}, RH_{out,t}, I_t, wind_t, Co2_{out,t}, \dots)$$

$$a_{1:T} = \{a_t\}, a_t = (u_{heat,t}, x_{vent,t}, cur_t, u_{co2,t}, \dots)$$

- 추정 대상(내부 숨은 상태)

$$x_{1:T} = \{x_t\}, x_t = (T_{ln,t}, e_{\epsilon,t}, Co2_t, \dots)$$

- 물리 파라미터

$$\theta = (UA, C, \eta, k_{heat}, \phi_{vent}, k_{evap}, k_{photo}, \dots)$$

(3) 물리 기반 상태공간모형(State-space model)구성

- 전이 프로세스 방정식: 단일 구획 모델 이산화 + 프로세스 잡음
 - 기존에 정의한 단일 구획 모델 f_{env} 를 상태 전이로 사용

$$x_{t+1} = f_{env}(x_t, a_t, u_t; \theta) + \xi_t$$

$$T_{\ln, t+1} = T_{\ln, t} + \frac{\Delta t}{C} \left[UA(T_{out, t} - T_{\ln, t}) + \eta AI_t^{eff} + k_{heat} u_{heat, t} + \rho c_p V \frac{ACH_t}{3600} (T_{out, t} - T_{\ln, t}) \right] + \xi_t$$

$$I_t^{eff} = I_t(1 - cur_t), ACH_t = g(x_{vent}, wind_t; \phi_{vent})$$

- 관측 방정식은 다음과 같이 정의하고 상대습도는 절대습도(선형식으로 변환하여 모델 정확도 향상)로 변환

$$y_t = h(x_y) + \epsilon_t, \quad \epsilon_t \sim N(0, R)$$

$$RH_{\ln, t} = \frac{e_{\epsilon, t}}{e_s(T_{\ln, t})}, \quad e(.): \text{포화수증기압}$$

(4) 사전 분포(Prior) 및 물리 제약

- 제한적 데이터에서 식별 불안정성을 방지하기 위해 사전확률 설정(사전확률은 선행연구들을 참조하여 새로 설정 가능함)

$$UA \sim \text{LogNormal}(\mu_{UA}, \sigma_{UA})$$

$$C \sim \text{LogNormal}(\mu_C, \sigma_C)$$

$$\eta \sim B(a_\eta, \beta_\eta), 0 < \eta < 1$$

$$k_{heat} \sim \text{LogNormal}(\mu_h, \sigma_h)$$

- Q, R은 Inv-Wishart 혹은 half-Cauchy등으로 추정 가능
- 물리적 부호 및 범위 제약

$$UA > 0, C > 0, k_{heat} > 0, 0 < \eta < 1, ACH \geq 0$$

(5) 이벤트 기반 부분 검증 위치 검색

- 1개월 전체 로그로 전체 식별을 하지 않고, 이벤트 구간의 사후 예측 분포를 확인하고 이벤트 구간에서 물리적 응답 방향/규모를 재현할 수 있는지를 먼저 확인
- 즉, 단일 채적 일치가 아닌 분포적 일치를 검증 단위로 채택

$$p(y_{t:t+L} | y_{1:t}, a_{t:t+L}, u_{t:t+L}) = \int p(y_{t:t+L} | x_{t:t+L}) p(x_{t:t+L} | x_t, \theta) p(x_t, \theta | y_{1:t}) dx d\theta$$

(5) 혼합 검증 구조 기반 견고성 입증(Particle MCMC posterior)

- 실측 로그로 posterior 구성

$$p(\theta, x_{1:T} | y_{1:T}) \propto p(\theta) p(x_1 | \theta) \prod_{t=1}^{T-1} p(x_{t+1} | x_t, \theta) \prod_{t=1}^T p(y_t | x_t)$$

- 단일 구획 모델은 비선형/비정상/비가우시안 요소를 포함할수 있으며 EKF/UFK 기반 근사는 정합성 확인에는 도움이 되나, 최악 위험(CVaR) 수준의 견고성 검증에는 근사 오차가 누적될 수 있는 문제를 가지고 있음
- Particle MCMC는 Particle 필터로 가능도(Likelihood) 편향이 없는(Unbiased) 추정이 가능하며, 비선형 상태공간에서 사후 파라미터 추론에 강점을 가지고 있음

- PMMH 알고리즘은 파라미터 주변 posterior $p(\theta|y_{1:T})$ 샘플링을 수행하며 particle filter로 가능도 $\hat{p}(y_{1:T}|\theta)$ 를 비편향 추정

초기화: $x_1^{(n)} \sim p(x_1|\theta)$, 가중치 $w_1^{(n)} \propto p(y_1|x_1^{(n)})$

반복(각 t):

① resampling: $\tilde{x}_{t+1}^{(n)} \sim \text{Resample}(x_t^{(n)}, w_t^{(n)})$

② propagate: $x_{t+1}^{(n)} \sim p(x_{t+1}|\tilde{x}_t^{(n)}, \theta)$

③ weight: $w_{t+1}^{(n)} \propto p(y_{t+1}|x_{t+1}^{(n)})$

- 가능도(Likelihood) 추정치 수식은 다음과 같음

$$\hat{p}(y_{1:T}|\theta) = \prod_{t=1}^T \left(\frac{1}{N} \sum_{n=1}^N w_t^{(n)} \right)$$

- PMMH 업데이트 프로세스는 다음과 같음

① 제안분포 $\theta' \sim q(\theta'|\theta)$

② $\hat{p}(y|\theta')$ 계산

③ 수용확률

$$\alpha = \min \left(1, \frac{p(\theta') \hat{p}(y|\theta') q(\theta|\theta')}{p(\theta) \hat{p}(y|\theta) q(\theta'|\theta)} \right)$$

④수용시 $\theta \leftarrow \theta'$

- 파라미터 블록으로 묶어 추정하고 추정 시 $\log(\theta)$ 로 변환하여 추정하여 물리 제약을 자동으로 반영

(6) 제어에 따른 내부 변화 검증과 견고성 평가 연결

- 실측 로그에서는 내부 상태 변화가 외기·일사·풍속 등의 영향과 혼합되어 관측되므로, 제어 입력의 순수 효과를 직접 분리 관측하기 어려움
- 따라서, 사후확률 기반 반사실(Counterfactual) 시뮬레이션을 통해 동일 외기 조건 하에서 제어만 바꿨을 때 내부가 어떻게 달라지는지를 분포 형태로 정의하고, 이를 견고성 성능지표(KPI) 및 최악위험(CVaR) 계산
- 외기·일사·풍속 등 경계조건은 실측 로그를 그대로 고정

$$u_{1:T} = \{u_t\}_{t=1}^T, \quad u_t = (T_{out,t}, RH_{out,t}, I_t, wind_t, Co2_{out,t}, \dots)$$

- 즉, 평가 중에는 $u_{1:T}$ 를 동일하게 두고, 제어 입력만 바꾸어 반사실 비교를 수행
- 동일한 입력 $u_{1:T}$ 하에서 다음 제어 시나리오를 비교함

$$a_{1:T}^{real} = \{a_t^{real}\}_{t=1}^T, \quad \text{실제 제어 로그(관측된 운전)}$$

$$a_{1:T}^{AI} = \{a_t^{AI}\}_{t=1}^T, \quad a_t^{AI} = \pi(\hat{x}_t, u_t; p_{policy}). \quad \text{AI 정책 제어(폐루프)}$$

$$a_{1:T}^{alt} = \{a_t^{alt}\}_{t=1}^T$$

- 사후확률 샘플별 시뮬레이션(Particle MCMC)을 통해 불확실성 포함 궤적을 생성

$$\theta^{(m)} \sim p(\theta|y_{1:T})$$

- 각 $\theta^{(m)}$ 에 대해 환경 반응 모델(단일 구획 동역학)을 전방 시뮬레이션

$$\hat{x}_{t+1}^{(m)} = f_{env}(\hat{x}_t^{(m)}, a_t, u_t; \theta^{(m)}), t = 1, \dots, T-1$$

- 이를 각 제어 시나리오마다 수행하여 실제 제어 로그, AI 정책 제어, 대안 제어의 수치를 산출함

(7) 제어에 따른 내부 변화 분포 정의

- 온도 기준 예시로, 동일 $u_{1:T}$ 하에서 AI 제어가 실제 제어 대비 내부 온도를 얼마나 바꾸는지를 다음과 같이 정의

$$\Delta T_t^{(m)} = T_{\ln,t}^{AI,(m)} - T_{\ln,t}^{real,(m)}, t = 1, \dots, T$$

- 이 분포는 제어 변경이 내부 환경 궤적에 미치는 영향을 추정치와 신뢰구간 형태로 제공하기 위함으로 온도 변화는 $\{\Delta T_t^{(m)}\}_{m=1}^M$ 으로 구성된 불확실성 포함 분포로 제시 가능

(8) 검증 지표

- 무데이터 환경에서의 검증 방법론 (7) 견고성 평가 지표의 지표들(온도 제약 위반율, 최대 연속 위반, 결로 위험 위반율, 과습/저VPD위반율, 난방-환기 동시 사용 비효율, 제어 안정성)의 지표를 안정성 중심 KPI로 정의하고, 이벤트 구간에서 ①관측값이 사후예측구간에 포함되는 비율, ②방향이 일관적인인지를 확인하기 위한 방향일치율의 두 지표를 추가적으로 현실 정합성 지표로 정의하여 산출함

- 현실 정합성 지표: 예측 구간 포함 비율

$$Cover_{\gamma}(E_i) = \frac{1}{|E_i|} \sum_{t \in E_i} 1[y_t \in CI_{\gamma}(y_t^{pred})]$$

- 현실 정합성 지표: 방향일치율; 실측 데이터가 모델이 허용하는 물리 반응 범위 안에 존재함을 정량적으로 확인

$$DirMatch(E_i) = \frac{1}{|E_i|} \sum_{t \in E_i} 1[sign(\Delta T_t^{obs}) = sign(\Delta T_t^{pred})]$$

- Posterior-robust 최악 위험(CVaR)⁹⁾ 수식은 다음과 같이 무데이터 환경 상황에서 사용한 검증지표를 사용하고, w 기상/스트레스 시나리오(예: 한파, 장기

저일사, 강풍 등)에서 각 조합의 지표 $M(\theta, w)$ 를 반복 계산

$$Q_{0.9}(M) = \inf\{m : P(M \leq m) > 0.9\}$$

$$CVaR_{0.9}(M) = E[M | M \geq Q_{0.9}(M)]$$

- 제한적 데이터 단계 통과 기준 또한 평균이 아닌 최악 분위에서도 임계 이하로 정의하고 운영 안전 기준 사전값 정의보다 수치가 낮을 경우 통과

$$Q_{0.9}(m_{cond}) \leq \tau_{cond}, \quad Q_{0.9}(m_{hv}) \leq \tau_{hv}, \quad Q_{0.9}(m_{T,run}) \leq L_T$$


(9) 제한적 데이터 기반 AI 자율제어 검증

- 경상북도 상주 실증단지 2025년 10월 16일부터 2025년 11월 15일을 샘플로 하여, 외부 환경은 실측 로그를, 내부 환경의 변화는 물리 기반 환경 반응 모델, 불확실성 물리 파라미터는 샘플링한 몬테카를로 시뮬레이션을 통해 생성하여 20번의 모의를 진행함
- 각 모의마다 물리 파라미터를 사전 분포에서 독립 샘플링하고 동일한 외기·일사 입력 하에서 페루프 제어 모의를 실행하고, 시간 평균 위반률, 최대 연속 위반 길이 그리고 제어 안정성 지표를 산출함

지표명	관측 범위	해석
온도 제약 위반률	약 0.38~0.49	전체 시간의 38~49%에서 온도 제약 이탈 발생
최대 연속 위반 길이	222~319 스텝	장기간 연속 이탈 구간 존재
결로 위험 위반률	0.047~0.136	전체 기간 중 5~14%
최대 연속 결로 위반	76~140 스텝	비교적 짧은 연속 구간
과습위반률	0.10~0.23	습도 제약 빈번
저VPD 위반률	0.26~0.46	생육 최적성 측면에서 불리
난방-환기 비효율	0.03~0.05	낮은 수준
환기 조작량	207.96	안정적 빈도
난방 스위칭 횟수	165	안정적 빈도

- 무데이터 단계에서 파라미터 불확실성이 큰 경우, 내부 열용량(C), 열손실(UA) 추정 오차가 누적되어 보수적이지만 느린 반응 또는 과도한 반응이 반복되는 것으로 보임
- 온도 제약 위반률과 최대 연속 위반 길이의 경우, 최악에 가까운 물리 가정 하에도 위 수준 정도의 위반이 발생할 수 있다는 상한 평가

- 결로 위반은 온도 제약 대비 상대적으로 낮은 수준에서 관리됨
- 이는 제어 정책이 온도 제약은 일부 희생하더라도 결로를 우선적으로 회피하는 방향으로 작동함을 시사(안전 우선 설계 원칙이 반영된 결과)
- 난방 중 환기로 인한 열손실은 엄격하게 억제됨
- 이는 제어 투명 단계에서 난방-환기 동시 사용 제한, 램프 제약이 효과적으로 작동했음을 의미함
- 이를 통해 AI 자율제어기(v3.0)은 불확실한 물리 환경에서도 제어 입력이 물리적으로 비합리적인 영역으로 가지 않음과 결로·에너지 측면의 즉각적 위험은 제한됨을 확인 가능
- AI 제어 정책은 평균 성능이 아니라 최악의 시나리오에서도 시스템을 망가뜨리지 않는 구조적 견고성을 가짐



5) 충분한 데이터 환경에서의 검증 방법론

(1) 충분한 데이터 환경의 정의 검증 전제

- 충분한 데이터 환경이란 다음 조건을 만족하는 경우를 의미함
 - 최소 1개월 이상의 연속적인 내부 환경 로그 확보
 - 해당 기간 동안의 실제 제어 로그 확보
 - 외기 기상 로그 동기화 완료
 - 단일 구획 모델(3.3절) 물리 파라미터가 안정적으로 식별·검증된 상태

(2) 검증 구조 개요

- 충분한 데이터 환경(실측 데이터 기반 검증)에서는 페루프 시뮬레이션이 아닌 ex-post 검증이 가능하여 입력은 실제 Controller의 출력 제어 로그, 실제 외기 로그, 실제 내부 환경 관측을 통해 물리 모델을 통한 예측 없이 관측된 내부 환경 값이 KPI 제약을 충족했는지 직접 평가
- 실측 데이터 기반 검증에서는 전에 정의한 안전성 중심 KPI를 그대로 유지: 온

도 제약 위반률, 최대 연속 위반 길이, 결로 위험 위반률, 과습 위반률, 난방-환기 동시 사용 비효율, 환기 개도 누적 변화량, 난방 스위칭 횟수를 사용하여 평가함

(3) 실측 KPI 기반 성능·안전성 평가

- 충분한 데이터 환경에서는 AI자율제어기의 성능과 안정성은 실제 운영 중 관측된 내부 환경 로그를 직접 사용하여 사후적으로(ex-post) 검증함
 - 온도 안정성: 온도 제약 위반률, 최대 연속 위반 길이
 - 결로 안정성: 결로 위험 위반률
 - 습도 안정성: 과습 위반률
 - 에너지·운영: 난방-환기 동시 사용 비효율
 - 제어 안정성: 환기 개도 누적 변화량, 난방 스위칭 횟수
- 평가는 ①평균 성능보다 위반 여부 및 지속성, ②단기 성능 향상보다 운영 안정성 우선으로 평가함

6) 외기 조건 고정 기반 정책 비교 시뮬레이션

- 본 절은 동일한 외기(경계조건) 시나리오를 고정한 상태에서, 서로 다른 제어정책(관측 제어/기본 규칙 이반/AI 정책)이 만들어내는 내부 상태 궤적(온도·습도·이산화탄소) 및 안정성 KPI를 비교·평가하는 시뮬레이션 방법론을 제시함
- 기본 10분 간격($\Delta t = 600s$) 이산 시뮬레이션을 기준으로 수행되며, 정책별 결과는 몬테카를로 반복 후 평균·최악분위로 집계함

(1) 검증 목적 및 핵심 아이디어: 외기 고정하 정책 차이의 순수 효과 비교

- 내부환경 변화는 외기온·습·일사·풍속 등 외부 요인에 의해 크게 좌우되므로, 정책 비교 시 외기(경계조건) 자체가 다르면 정책 성능 차이가 왜곡될 수 있음
- 따라서 본 비교 시뮬레이션은 동일한 외기 시계열을 모든 정책에 동일하게 입력하고, 정책에 따라지는 제어 입력에 따라 ①관측제어: 실증단지에서 실제로 실행된 제어 로그 재생, ②규칙기반: 온도 데드밴드 기반 난방/환기 + 일사 임계 기반 차광, ③AI 최적화 기반: 후보행동 격자 탐색 + 원스텝 물리 예측 + 비용함수의 3가지 정책을 비교함

(2) 입력·상태 정의

- 기존에 정의한 데이터 수집·정렬·정규 시간격자화 및 파생변수 계산 절차를 그대로 수행

(3) 외기 조건 고정 기반 비교 설계

- 정책 비교는 동일한 기간에 대해 다음 조건을 강제함

- 외기 입력 동일성: 모든 정책에 대해 동일한 외기 경계조건을 사용함
- 초기조건 동일성: 모든 정책의 초기 내부 상태는 동일하게 설정함
- 모델·제약 동일성: 환경 반응 모델 $f(\cdot)$, 물리 파라미터 θ 의 설정(또는 불확실성 샘플링), 그리고 제어 입력의 안전 제약(박스, 램프, 규칙)은 정책 간 동일하게 적용하여 차이는 오직 정책이 산출한 제어 정책에 의해서만 발생함
- 전체 데이터 구간에 대해 핵심 파라미터(UA, 난방용량, 최대 환기율 등)를 점추정으로 적합 후 모든 정책 비교 및 몬테카를로 반복에서 동일한 $\hat{\theta}^*$ 를 고정하여 사용
- 이 설계는 정책 비교 단계에서의 불확실성 원인을 파라미터가 아닌 정책과 제어 시퀀스에서 찾기 위함임. 즉, 본 시뮬레이션의 목적은 어떤 파라미터 분포에서 평균적으로 좋은 정책을 찾는 것이 아니라, 동일한 물리 가정 하에서 정책 구조 자체가 안전 제약을 얼마나 잘 유지하는가를 비교하는데 목적이 있음

(4) 내부 환경 반응 모델(단일 구획 이산 동역학)

- 정책 비교는 단일 구획을 이산화한 전방 시뮬레이션으로 동일하게 수행함(수식은 무데이터 환경에서의 검증 방법론 수식들 참조)
- 환기율(ACH)변환: 환기 개도율과 외기 풍속, 필요 시 팬 구동 정보를 결합해 ACH_t를 정의하며, 물리적으로 포화되는 준선형/포화 상태의 변환 사용
- 온도 동역학: 일사에 의한 열유입, 난방에 의한 열유입, 외기와의 열손실(전도/누설), 환기에 의한 교환항을 포함한 에너지 수지 기반 갱신식 사용
- 수분 동역학: 내부 수분은 환기 교환항과 증발·증산을 포함해 갱신
- 이산화탄소 동역학: 환기 교환 - 광합성 흡수(일사 및 농도 포화형)을 포함해 갱신

(5) 제어 입력 사전 검증 및 안전 투영

- 무데이터, 불확실성 환경에서 정책 비교 핵심은, 어떤 정책이든 생성한 제어 입력이 물리적으로 불가능하거나 위험한 영역으로 진입하지 않도록 입력 검증과 투영을 공통적으로 적용해야함. 그러므로 제어 입력 u_t 는 환경모델에 적용되기 전 3가지 다음 절차를 거침
- 박스 제약: 각 제어 입력은 장비의 표현 범위 및 구동 제약을 만족해야함
- 램프 제약: 급격한 제어 변화는 장비 부하 및 동역학적 불안정을 유발할 수 있으므로, 단위 시간당 변화량을 제한
- 안전 규칙: 사전에 정의된 금지 조합이 존재하는 경우 이를 차단함
- 입력이 박스, 램프, 규칙을 위반할 경우, 안전 제어로의 투영 문제를 풀어 최종 적용 제어 $\tilde{u}_t$ 를 결정함

$$\tilde{u}_t = \arg \min_{u \in U_{safe}} \|u - u_t\|$$

- 여기서 U_{safe} 는 박스·램프·규칙을 동시에 만족하는 안전 제어 집합으로 투영 단계는 정책 간 비교에서 공통 적용되어, 정책 차이가 안정장치 유무가 아닌 정책 자체의 선택 성향에서 발생하도록 함

(6) 비교 정책 정의

- 정책은 ①관측 제어: 실증단지에서 실제로 실행된 제어 로그를 시퀀스로 입력하되 안전 투영 단계에서 물리적으로 불가능하거나 위험한 입력은 보정함, ②규칙 기반: 온도 목표와 데드밴드에 기반한 난방·환기 규칙, 그리고 일사 임계 기반의 차광 및 이산화탄소 공급 규칙 적용(이는 대부분의 복합환경제어기들이 사용하고 있는 규칙 기반 제어로써 설명가능한 기본 운전 로직으로 AI 정책과의 비교 기준선 역할을 함), ③최적화 기반 AI 자율제어 정책: 매 스텝에서 후보 행동 집합을 생성하고, 단기 예측을 통해 제약 위반 위험 및 목표 편차를 평가한 후 비용함수 최소화를 제어를 선택 하는 3가지의 정책을 비교함

(7) 정책 비교 페루프 시뮬레이션 절차

- 외기 조건 고정 비교는 ①비교 구간 정의, ②초기값 설정, ③정책별 페루프 시뮬레이션, ④정책 간 비교의 4 단계 절차로 수행됨
- 정책별 페루프 시뮬레이션은 다음과 같이 수행됨
 - 정책 산출: $u_t^{raw} = \pi^k(x_t, w_t)$
 - 안전 투영: $\tilde{u}_t = Proj(u_t^{raw})$
 - 상태 전이: $x_{t+1} = f(x_t, w_t, \tilde{u}_t; \theta)$
 - 궤적 및 제어 저장: $\{x_t, \tilde{u}_t\}_{t=0}^T$
- 동일 w (외기 경계조건), x_0 (내기 조건 시작점), 동일 제약/모델 하에서 산출된 궤적 차이를 KPI로 정량화 함

(8) 불확실성 반영을 위한 잔차 기반 몬테카를로 시뮬레이션 반복

- 모델 미스매치 및 미설명 동역학을 반영하기 위해 잔차 기반 불확실성을 사용함
- 잔차 구성은 다음의 절차로 구성함
 - 관측 제어를 사용해 원스텝 예측 수행
 - 관측된 다음 상태와의 차이를 잔차로 저장
 - 잔차는 상태 성분별(온도, 수분, 이산화탄소)로 구성된 경험적 샘플 집합으로 취급
- 몬테카를로 반복이 활성화된 경우, 각 시뮬레이션 스텝마다 잔차 샘플을 무작위로 선택하여 상태 업데이트에 가산함. 이를 통해 동일한 정책이라도 ①누적 오차에 의해 상태 궤적이 달라질 수 있으며, ②정책의 안정성은 단일 궤적이 아니라 궤적 분포로써 평가할 수 있음

(9) KPI 성능 계산 및 꼬리 위험 기반 평가

- 사전에 정의한 안정성 중심 KPI 계산(6종)으로 최악 위험을 평가

VI 연구결과 종합 및 기술적 한계와 확장 방향

4.1 연구결과의 종합적 요약 및 구조적 성과 정리

- 본 기술 문서는 스마트온실 환경에서 AI 자율제어 기술을 대상으로, 시설·장비·환경의 이중성이 크고 데이터 가용성이 불균일한 현실적 조건 하에서 안정적으로 작동하는 범용 제어 엔진을 구현하는 것을 궁극적 목표로 수행됨
- 특히 기존 스마트온실 AI 제어 기술이 전제해 온 충분한 데이터, 표준화된 장비 제원, 균일한 물리 환경이라는 가정이 실제 현장에서는 성립하기 어렵다는 문제의식에서 출발하여, 물리 일관성을 유지하는 페루프 제어 구조와 단계적 검증 체계를 동시에 설계·구현함

□ 연구 결과의 종합적 요약

- **센서값 중심 제어에서 물리·생리 상태공간 기반 제어로의 구조적 전환 구현:** 기존 AI 기반 환경 제어는 온·습도 등 센서 관측값을 직접 입력으로 사용하는 경우가 대부분으로, 실제 재배 환경의 물리적 상태를 충분히 반영하지 못하는 구조적 한계를 가지고 있음. 본 연구는 센서 관측값에서 출발을 하되, 이를 물리·생리적 의미를 갖는 파생 상태량으로 재구성하여 상태(State) 자체가 물리적 의미를 가지도록 설계하고 이를 통해 제어 의사결정이 단순한 수치 반응이 아니라, 온실 내부의 물리·생리 상태 변화에 기반하여 이루어지는 구조를 확립함
- **온실 및 장비의 이중성을 고려한 물리 적응형 제어 구조:** 국내 스마트온실은 지역·시설별로 단일 성능, 체적, 환기 특성, 장비 구성 및 제원이 상이하며, 상당수의 경우 정확한 설계 제원이 존재하지 않음. 본 연구에서는 이러한 현실을 전제로, 실측 데이터 기반 물리 파라미터 자동 식별 및 장비 응답의 데이터 기반 역추정을 통해, 장비 제원이나 설계 정보가 부재한 환경에서도 적용 가능한 제어 구조를 설계함. 이는 특정 시설에 종속된 제어기 개발이 아닌, 이중 환경에 대해 물리적 일관성을 유지하며 적응하는 범용 제어 엔진이라는 것이 본 연구의 핵심임
- **페루프 상태 궤적을 중심으로 한 제어 정책 검증 문제 정의:** 기존의 많은 제어 성능 평가는 단일 시점의 제어 명령 정확도 또는 평균적인 환경 유지 성능에 초점을 둠. 본 연구에서는 제어 정책이 생성하는 제어 시퀀스 전체가 페루프 시스템에서 만들어내는 내부 상태 궤적의 안정성을 검증의 중심 대상으로 설정함. 이에 따라 검증은 항상 상태-행동-전이가 연결된 페루프 합성계에 대해 수행되며, 단기적인 성능 향상보다는 제약 위반의 빈도와 지속성, 그리고 누적 위험을 중심으로 평가함
- **데이터 가용성 수준에 따라 최적 제어 성능 평가와 안정성 검증을 모두 포괄하는 단계적 프레임워크 제시:** 본 연구는 데이터가 충분히 축적된 환경에서는 제어 정책의 평균 성능, 제약 준수율, 제어 안정성 및 운영 효율을 포함하는 최

적 제어 성능 평가가 가능함. 하지만, 스마트온실의 속성상 데이터가 제한적이거나 전혀 존재하지 않는 초기 도입 상황이 많고 AI 자율 제어기 도입시 최적 제어 성능 평가가 사전적으로 필요한 경우를 대비하여 물리적으로 위험한 상태로의 진입 여부를 사전에 검증하는 안정성 중심의 평가를 수행할 수 있는 방법론을 제시함

□ 구조적 성과의 핵심 의의

- 본 연구의 핵심 의의는, 제어기 설계와 검증 체계를 동시에 구조화함으로써, 언제 어떤 수준까지의 평가가 가능한지를 명확히 규정할 수 있는 틀을 제시하는데 있음 구체적으로는,
 - 데이터가 충분한 경우, 물리·생리 상태공간 기반 제어를 바탕으로 최적 제어 성능 평가까지 가능한 구조 제공
 - 데이터가 부족한 경우에도 제어 정책이 물리적으로 비합리적인 영역으로 확산되지 않음을 사전에 검증할 수 있도록 함
 - 두 경우가 서로 다른 연구 체계가 아니라 동일한 제어·검증 프레임워크 내에서 자연스럽게 전환되도록 설계함
- 즉, 본 연구는 가용데이터가 있을 경우 온실의 물리적 제원, 장비 이중성을 반영하여 성능을 지속적으로 향상시킬 수 있는 AI 자율제어기, 현실적인 데이터 제약 하에서도 신뢰 가능한 판단을 가능하게 하는 제어·검증 구조 자체를 성과로 제시한다는 점에서 기존 연구와의 차별성을 가짐

4.2 적용 범위 정의 및 기술적 전제 조건

□ 적용 범위 정의

1) 대상 시스템 범위

- 본 연구 적용 대상은 단일 구획(Single-compartment) 스마트온실 환경을 기존 전제로 함. 특히 여기서 단일 구획 정의란 온실 내부를 하나의 평균적 환경 상태로 대표할 수 있는 구조를 의미하며, 다음과 같은 특성을 가짐
 - 내부 온도, 습도, 이산화탄소 농도가 공간적으로 완전히 균질하지는 않더라도 제어 관점에서 평균 상태로 대표 가능한 수준
 - 난방, 환기, 차광, 이산화탄소 공급(상주 실증 단지 제외) 등 기본적인 환경 제어 수단 보유
 - 외기 온도, 외기 습도, 일사, 풍속 등 외부 경계조건에 대한 예측 가능
- 위와 같은 범위 내에서 본 연구의 제어·검증 구조는 온실 규모, 구조, 지역이 상이하더라도 공통적으로 적용이 가능하도록 설계됨

2) 데이터 가용성에 따른 적용 단계

- 본 연구는 적용 환경을 데이터 가용성 수준에 따라 명확히 구분하며, 각 단계별로 적용 가능한 지능과 검증 목적이 상이함

구분	데이터 가용성 조건	주요 적용 범위	검증 목적 및 해석 수준
충분한 데이터 환경	내부 환경 · 외기 · 제어 로그가 1개월 이상 연속 확보	물리 파라미터 안정적 식별, 정책 비교 및 보정	최적 제어 성능 평가(평균 성능, 제약 준수율, 효율 포함)
제한적 데이터 환경	수일~수주 수준 로그 확보, 계절 · 극단 조건 미포함	반사실 시뮬레이션 기반 정책 평가	성능은 비교 가능하나 절대적 최적성 해석에는 제한, 최악 위험 중심 평가
무데이터 환경	실측 내부 로그 부재 또는 극히 제한적	물리 모델 기반 시뮬레이션	최적성 평가는 수행하지 않으며, 제어의 물리적 합리성, 안정성 검증에 한정

□ 기술적 전제 조건

- 본 연구의 제어 및 검증 결과는 다음의 기술적 전제 조건을 만족하는 환경에서 해석되어야함

구분	전제조건	해석상 의미
시스템 구조	단일 구획 온실	내부 환경을 평균 상태로 대표 가능
외기 계측	외기 온도, 습도, 일사, 풍속 계측 가능	외부 경계조건 고정 기반 비교 가능
제어 수단	난방, 환기, 차광 등 기본 구동기 보유	표준 환경 제어 범위 내 적용
상태 표현	물리 · 생리 파생 상태 사용	물리 · 생리 일관성 확보
물리 모델	방향성 · 보수성을 갖는 근사 모델	예측 정확도 보다 제어 안정성 중심
장비 제원	장비 제원 부재 또는 불확실성 허용	데이터 기반 장비 반응 추정
제어 제약	박스, 램프, 안전 규칙 항상 적용	정책 무관 안정성 보장

□ 적용 범위의 해석적 한계 및 주의사항

- 앞서 정의한 적용 범위와 기술적 전제 조건에 따라, 본 연구의 결과는 다음과 같은 환경에서는 해석에 주의가 필요함
 - 다중 구획 또는 복층 구조로 인해 공간적 환경 차이가 지배적인 온실
 - 국부 결로, 미기상, 장비 국소 고장 등 미시적 현상이 제어 성능을 좌우하는 경우
 - 생육 성과(수량·품질)를 직접 목적 함수로 최적화하는 장기 운영 문제의 경우
- 이러한 경우 본 연구의 단일 구획 기반 제어·검증 구조는 초기 안정성 확보 또는 사전 검증 단계로 활용하는 것이 적절하며, 공간 분할 모델 또는 생육 모델과의 추가 결합이 요구됨

4.3 현재 AI 자율제어·검증 엔진의 구조적 한계점

□ 데이터 가용성 조건에 따른 파라미터 불확실성 처리의 한계

- 본 연구의 제어·검증 엔진은 데이터 가용성 수준에 따라 서로 다른 방식으로 접근하도록 설계되어 있음. 데이터가 충분한 환경에서는 내부 환경 및 제어 로그를 활용하여 온실별 물리 파라미터를 비교적 안정적으로 식별하고, 이를 기반으로 제어 정책의 성능 평가 및 보정 수행이 가능함. 반면, 데이터가 제한적이거나 전혀 존재하지 않는 환경에서는 물리 파라미터의 신뢰성 있는 식별이 구조적으로 불가능함
- 무데이터 환경에서는 물리 파라미터를 사전확률 또는 보수적 범위로 가정하는 접근적 이론이 필요함. 본 연구에서도 파라미터 불확실성을 개념적으로 전제하고 있으나, 실제 구현에서는 명시적인 사전확률 분포 샘플링이나 분포 기반 정책 최적화를 수행하지 않음. 이는 파라미터 분포 자체에 대한 가정이 또 다른 불확실성을 도입할수 있으며, 초기 도입 단계에서 요구되는 핵심 기능이 성능 최적화가 아닌 물리적 합리성 검증(AI 자율제어기 정책 안정성)이라는 판단에 따른 설계임

□ 단일 그획 가정에 따른 공간 해상도의 구조적 한계

- 본 연구의 제어·검증 엔진은 온실 내부를 하나의 평균적 상태로 대표하는 단일 구획 구조를 전제로 함. 이 가정은 다양한 구조와 규모의 온실에 범용적으로 적용 가능한 제어 엔진을 구현하기 위함임
- 그러나 이와 같은 단일 구획 가정은, 온실 내부에서 발생하는 국부적인 온·습도 편차, 미기상 현상, 국소 결로 위험과 같은 공간적 이질성을 직접적으로 표현하지 못하는 한계를 가짐. 특히 대형 온실이나 복층 구조, 국부 환기 또는 부분 난방이 지배적인 환경에서는 평균 상태 기반 제어가 국부 위험을 과소평가할 가능성이 존재함
- 본 엔진은 공간적으로 세밀한 제어 성능을 목표로 하기 보다는, 온실 전체 수준

에서 물리적 안정성과 제약 준수를 보장하는 최소 조건을 확보하는 목적을 둔 설계 철학을 가지고 있음. 따라서 공간 해상도 한계는 본 엔진이 제공하는 안정성 검증의 범위를 규정하는 요소로 보아야 하며, 이는 설계상의 결함으로 간주되지 않음

□ 목적 함수 및 운영 목표 범위의 한계

- 본 연구의 제어·검증 엔진은 제어 안정성과 물리적 합리성을 우선하는 설계 철학을 기반으로 구성되어 있으며, 이에 따라 정책의 목적 함수는 안전 제약 준수와 상태 안정성 유지에 중점을 두고 있음
- 이러한 설계로 인해, 난방 사용에 따른 에너지 비용 최소화, 운영 비용 최적화와 같은 경제적 목적은 최적화 대상으로 포함되지 않음
- 또한 본 엔진은 작물의 수량, 품질, 생육 속도와 같은 생육 성과를 직접적으로 최적화하지 않으며, 생육 모델과의 결합을 통해 장기적인 생육 성과를 예측·최적화 하는 구조를 포함하지 않음. 이는 생육 성과 최적화가 상당한 데이터 축적과 작물·시설별 맞춤 모델링을 요구하는 고차원 문제이며, 향후 본 연구에 이어 고도화로 이어가야하는 부분이기 때문임
- 따라서 본 엔진의 목적 함수 및 운영 목표 범위의 한계는, 안정성과 재현성을 확보한 이후에 의미 있는 성능 최적화가 가능하다는 단계적 접근 전략에 따른 결과로 이해되어야함

□ ※ 경상북도 상주 실증단지 전력 사용료 산정 구조에 따른 에너지 최적화 한계

- 현재 실증 온실에서의 전력 사용료는 제어 엔진이 직접 최적화 대상으로 삼기 어려운 복잡한 외생 산정 구조를 따름. 구체적으로, 온실 전기 사용은 복합환 경제어장치 가동용 전력과 히트펌프 냉난방 운전에 사용되는 전력으로 구분되며, 이 중 히트펌프 전력 사용료는 단순한 사용 시간이나 소비 전력량에 비례하지 않음
- 히트펌프 냉난방 전력의 경우, 농진원이 전력을 선납한 후 실제 사용량을 기준으로 사후 정산하는 구조를 가지며, 전력 사용료는 레일 및 FCU 사용 유량을 기준으로 배분됨. 또한 지열발전에 사용된 전력량 요율은 월별 지열 사용량과 청구서상 총 전력 사용량의 비율을 통해 계산되며, 기본요금은 이용 온실 면적 비율에 따라 별도로 산정됨
- 이러한 전력 요금 산정 구조에서는, 동일한 히트펌프 작동 시간이나 유사한 제어 스퀀스라 하더라도, 월별 지열 사용량, 전체 전력 사용량, 온실 면적 비율 등 제어 엔진 외부에서 결정되는 변수에 따라 실제 비용이 달라질수 있으므로, 이를 목적 함수에 직접 포함하여 최적화 하는 것은 구조적으로 제한됨

4.4 제어·검증 엔진의 안정성 확보 구조 및 단계적 고도화 전략

1) 제어 입력 수준에서의 구조적 안정성 확보

- 본 연구의 제어·검증 엔진에서 안정성 확보의 가장 핵심적인 계층은 제어 입력 수준에서의 구조적 제한으로 이는 제어 정책의 성능이나 설계 완성도와 무관하게, 물리적으로 위험한 제어 명령이 실제 시스템에 전달되지 않도록 보장하는 공통 계층으로 작동함. 구체적으로 모든 제어 입력은 정책 출력 이후 다음의 절차를 거침
 - 박스 제약: 각 제어 입력은 장비의 물리적 구동 범위 및 표현 범위를 반드시 만족해야함
 - 램프 제약: 단위 시간 내 제어 변화량을 제한하여, 장비 과부하 및 급격한 환경 변화를 방지함
 - 안전 규칙: 난방-환기 동시 과도 사용과 같이 물리적으로 비합리적인 조합을 구조적으로 차단함
 - 투영 기반 보정: 상기 제약을 위반하는 경우, 제어 입력은 가장 가까운 안전 영역으로 자동 투영됨
- 이러한 입력 안정성 계층의 핵심 특징은, 제어 정책이 무엇을 의도하든 실제 시스템에 전달되는 제어는 항상 안전 제약을 만족한다는 점으로 이는 엔진 구조 자체에 의해 보장되는 하한의 성질을 가짐

2) 페루프 상태 궤적 수준에서의 안정성 확보 메커니즘

- 제어 입력이 단일 시점에서 안전하더라도, 반복 적용 과정에서 내부 상태가 누적적으로 불안정해질 가능성이 존재하므로, 안정성을 단일 제어 시점이 아닌, 페루프 상태 궤적 전체의 성질로 정의하고 다음과 같은 메커니즘을 내제함
 - 제어 후보는 항상 단기 예측 기반 제약 검증을 거친 후에만 실행 가능 집합에 포함됨
 - 제어 효과는 고정된 선형 계수가 아니라, 내부 상태 및 외기 조건에 따라 조절되는 상태 의존 민감도로 반영됨. 이로 인해 동일한 제어 입력이라도, 환경이 불리한 조건에서는 효과가 자동으로 완화되어 과도한 상태 변화를 억제함
 - 단일 구획 기반 환경 모델은 평균 상태를 기준으로 보수적으로 설계되어 있으며, 이는 상태 예측이 낙관적으로 치우치는 것을 구조적으로 방지함. 이러한 보수성은 페루프 제어에서 제약 위반의 연속적 확대를 억제하는 방향으로 작동함

3) 불확실성 하에서의 견고성 확보 및 한계 완화 전략

- 안정성 확보 구조는 파라미터 불확실성이 존재하는 환경에서 유지됨. 본 연구는

파라미터 불확실성을 즉시 제거하기보다, 불확실성이 존재하더라도 안정성 성질이 붕괴되지 않도록 설계하였음

- 무데이터 또는 제한적 데이터 환경에서는 물리 파라미터의 정확한 식별이 불가능하므로, 본 엔진은 파라미터를 적극적인 최적화 변수로 사용하지 않는 대신 제어 입력과 상태 전이 과정에서의 보수적 제약과 투영 구조를 통해 불확실성 하에서도 위험한 제어로의 이탈을 구조적으로 차단함
- 데이터가 점진적으로 축적될 경우, 파라미터는 이벤트 기반 식별 및 사후 분포 축소를 통해 점차 신뢰도를 높일 수 있으며, 이 과정에서도 안정성 계층은 동일하게 유지가 가능. 나아가 충분한 데이터 환경에서는 사후확률 기반 다중 시나리오 시뮬레이션, 최악 위험(CVaR) 기준 정책 선택 등으로 견고성 평가 및 제어 전략 고도화가 가능함

4) 운영 목표 및 목적 함수 고도화를 통한 안정성 확장

- 현재 엔진은 안전 제약 준수와 상태 안정성을 최우선 목표로 설계되어 있으며, 난방·냉방에 따른 실제 전력 비용이나 생육 성과는 최적화 대상으로 포함하지 않음(경상북도 실증단지 전략 사용료 산정 구조에 따른 에너지 최적화 한계 참조)
- 다만 요금 산정 구조가 명확히 모델링되고 제도적 조건이 정형화될 경우, 본 엔진은 다음과 같은 확장이 가능함
 - 제어 스퀀스 기반 예상 비용 산출
 - 비용-안정성 간 다목적 최적화
 - 비용 제약을 포함한 정책 탐색
- 또한, 현재 엔진은 생육에 의미 있는 물리·생리 상태공간 중심으로 의도적으로 설계되었으며, **향후 생육 모델을 결합해 생육 성과 기반 목적 함수로 확장할 수 있도록** 구성되어 있음

4.5 현장 적용성 및 실증 확장 가능성

- 본 연구에서 개발한 AI 자율제어·검증 엔진은 모든 스마트온실에 적용되는 것이 아닌 확산 단계에서 현실적으로 **충족 가능한 농가 환경 조건을 전제로** 단계적으로 적용되어야함. 확산 단계 농가 적용에서 요구되는 최소 적용 조건은 다음과 같음
 - 내부 온·습도 센서, 외기 온도 및 일사 센서 등 기본 환경 계측 인프라가 구축된 온실
 - 난방, 환기, 차광 등 기본적인 환경 제어 장치가 설치되어 있으며 원격 또는 자동 제어가 가능한 환경
 - 기존 복합환경제어장치 또는 운영 로그를 통해 제어 명령 이력이 확보 가능한 구조

- (초기단계) 데이터가 거의 축적되지 않은 농가 환경에서도, 본 엔진은 제어를 직접 생성하지 않고 기존 운전 결과를 검증·보정하는 방식으로 적용 가능. 이 단계에서는 엔진이 운영 방식에 개입하지 않으면서도 위험 제어를 사전에 차단하는 역할을 수행하므로, 확산 사업에 요구되는 초기 현장 리스크 관리에 적합함
- (중간단계) 중간 확산 단계에서 적용은, 다음과 같은 **권장 환경 조건**을 충족하는 농가를 대상으로 수행 필요
 - 최소 1달 이상의 내부 환경 및 제어 로그 축적
 - 제어 장비의 기본 응답 특성이 데이터로 관측 가능한 상태
 - 운영자가 AI 제어 일부 적용에 대해 실험적 운영을 수용할 수 있는 환경
- 이 단계에서는 엔진이 특정 시간대 또는 특정 제어 항목에 한해 제어 후보를 생성하고, 기존 제어와 병행 운용하는 혼합 적용 방식이 가능
- 충분한 데이터가 축적된 농가 환경에서는, 본 엔진을 페루프 자율제어 모드로 적용 가능함
- 다농가 확산을 위한 적용 전략에서는 제어·검증 엔진의 핵심 로직은 공통으로 유지하고, 농가별로 상이한 요소는 다음 항목에 한해 분리 관리함
 - 물리 파라미터(열손실, 열용량, 환기 특성 등)
 - 장비 반응식(난방기, 환기창, 차광장치 등)
 - 운영 로그 및 환경 데이터
- 이 구조를 통해 확산 사업 주관 기관은 농가별 환경 차이를 엔진 수정 없이 관리할 수 있으며, 대규모 보급 시 운영 부담 최소화 가능
- 실증 확장 과정에서 성과 평가는 개별 농가의 절대적인 생산성 향상보다는, 제어 실패율 감소, 위험 제어 사전 차단 사례, 운영 안정성 확보 여부를 중심으로 수행되어야함

4.6 향후 연구 및 기술 고도화 방향

- 본 장에서는 본 연구에서 개발한 AI 자율제어·검증 엔진을 기반으로, 향후 연구 및 기술 고도화가 어떤 방향과 단계로 진행될 수 있는지를 제시함. 특히 본 연구는 초기 도입 단계에서의 안정성 확보를 최우선 목표로 설정하였으나, 이는 성능 최적화를 단계적으로 이루기 위한 데이터·제도·운영 조건의 성숙에 따라 단계적으로 확장 가능한 구조를 확보하기 위한 전략적 선택임을 전제로 함 W

1) 데이터 축적에 따른 파라미터 추론 및 검증 고도화

- 향후 연구에서는 현장 적용 및 확산 과정에서 축적되는 내부 환경 로그와 제어 로그를 활용하여, 물리 파라미터 식별 정밀도를 단계적으로 향상시키는 방향으로 고도화를 추진할 수 있음. 특히 무데이터 또는 제한적 데이터 환경에서 개념적으

로만 가정되었던 파라미터 불확실성을, 실측 기반 사후확률 형태로 점진적으로 축소하는 연구가 필요함

- 이를 위해 이벤트 기반 부분 식별, 사후 예측 분포 검증, 반사실 시뮬레이션을 결합한 분포적 파라미터 추론 체계로의 확장이 가능하며, 파라미터 추정 결과는 단일 점추정이 아닌 신뢰구간 또는 위험지표형태로 제어 정책에 반영 가능
- 이러한 고도화는 제어 엔진의 안정성 계층을 유지한 상태에서 이루어지며, 데이터가 축적될수록 제어 정책의 보수성은 완화되고 성능 중심 운용으로 자연스럽게 전환이 가능함

2) 전력 요금 산정 모델 내재화 및 에너지 비용 최적화

- 본 연구에서는 실증 환경의 전력 요금 산정 구조가 다수의 외생 변수와 사후 정산 메커니즘을 포함하고 있음에, 에너지 비용을 최적화 대상으로 포함하지 않음. 향후 연구에서는 이러한 요금 산정 메커니즘을 정형화·모델링하여, 제어 엔진 내부에 비용 계산 계층을 추가하는 방향으로 고도화가 가능함
- 구체적으로는 제어 시퀀스 기반 예상 전력 사용량 산출, 유량-전력량 배분 규칙 모델링, 면적·사용량 비례 기본요금 반영 등을 포함한 운영 비용 추정 모듈이 필요하며, 이를 통해 비용-안정성 간의 다목적 최적화 문제를 정의할 수 있음

3) 생육 모델 결합을 통한 성과 기반 제어로의 확장

- 현재 제어·검증 엔진은 생육에 의미 있는 물리·생리 상태공간을 중심으로 설계되어 있으나, 생육 수량·품질과 같은 성과 지표를 직접 최적화 대상으로 포함하지 않음. 향후 연구에서는 작물별 생육 모델을 결합하여, 제어 정책의 목적 함수를 생육 성과까지 확장하는 연구가 가능함
- 이 경우에도 제어 엔진의 안정성 계층은 유지되며, 생육 성과 최적화는 안전 제약을 만족하는 범위 내에서 수행하는 방식으로 엔진을 고도화 시키는 방향으로 개발이 가능함
- 장기적으로는 생육 성과-에너지 비용-환경 안정성을 동시에 고려하는 다목적 제어 프레임워크로 확장이 가능함

4) 다구획·대형 온실로의 공간 확장 연구

- 본 연구는 단일 구획 기반 제어·검증 엔진을 전제로 하나, 향후 연구에서는 대형 온실 또는 복층 구조 등 다구획 확장 연구가 필요함. 이는 기존 엔진을 이용하여, 구획 단위로 동일한 엔진을 병렬 적용하고 상위 계층에서 조정하는 구조로 확장하는 방향이 적합함
- 이러한 확장은 센서 밀도 증가, 구획 간 상호작용 모델링, 제어 충돌 제어 조정 로직 등을 포함하며, 단계적 실증을 통해 안정성을 검증한 이후 적용하는 것이

바람직한 함